血液细胞与 L1000 扰动谱的 Lasso 分析报告

日期：2026-10-26（Asia/Shanghai）。四部分分析均已完成；原始数据未修改。

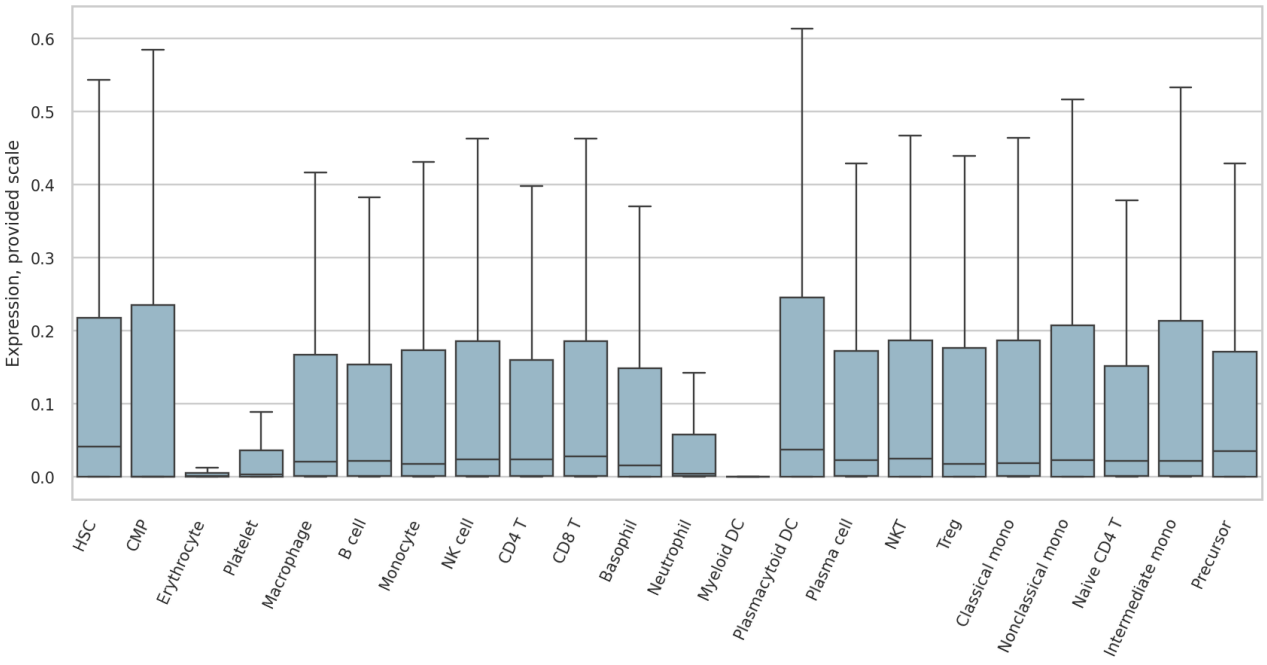
一、质控与预处理

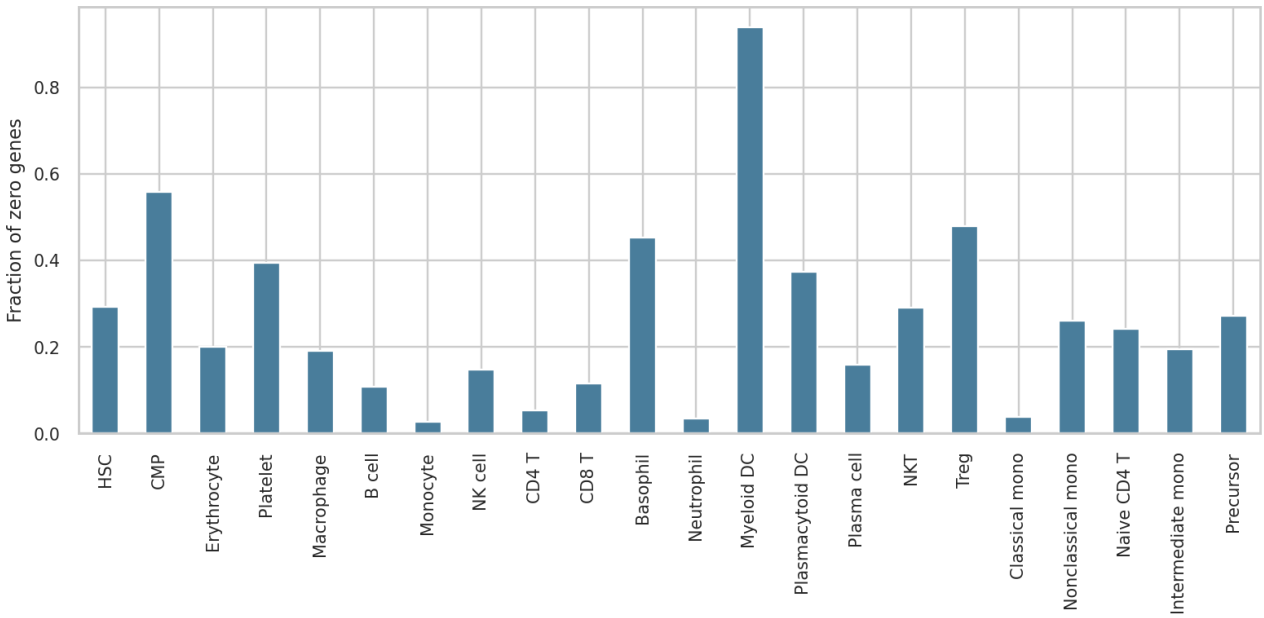
数据	原行数	列数	唯一基因数	重复行数	缺失	无穷值	最小值	最大值
blood	20001	22	19994	7	0	0	0.000	8.778
L1000	12328	2717	12327	1	0	0	-10.000	10.000

血液数据删除 7 个重复行（涉及 MATR3、MKKS、HERC3、POLR2J3、NPIPA9、PINX1），L1000 删除 1 个重复行（MIA2）；均保留原文件第一次出现。两套数据均无缺失值和无穷值。血液基因包含 580 个 Ensembl 格式标识，L1000 为符号格式；这些 Ensembl 行未精确匹配到 L1000，本次未推断其符号映射。该损失已记录，后续可在核实版本后映射。

按共同标识和相同顺序对齐后，共有 11,940 个基因、2,717 个扰动，其中 286 个扰动匹配 Lambert 人类 TF 名单。没有零方差扰动被剔除。血液表达范围 0 – 8.778474；其完整归一化来源未知，主分析采用提供尺度，不再盲目取对数。L1000 范围约 -10 – 10，作为有符号扰动特征使用，不取对数，也不将其声称为已核实的原始 log-fold change。

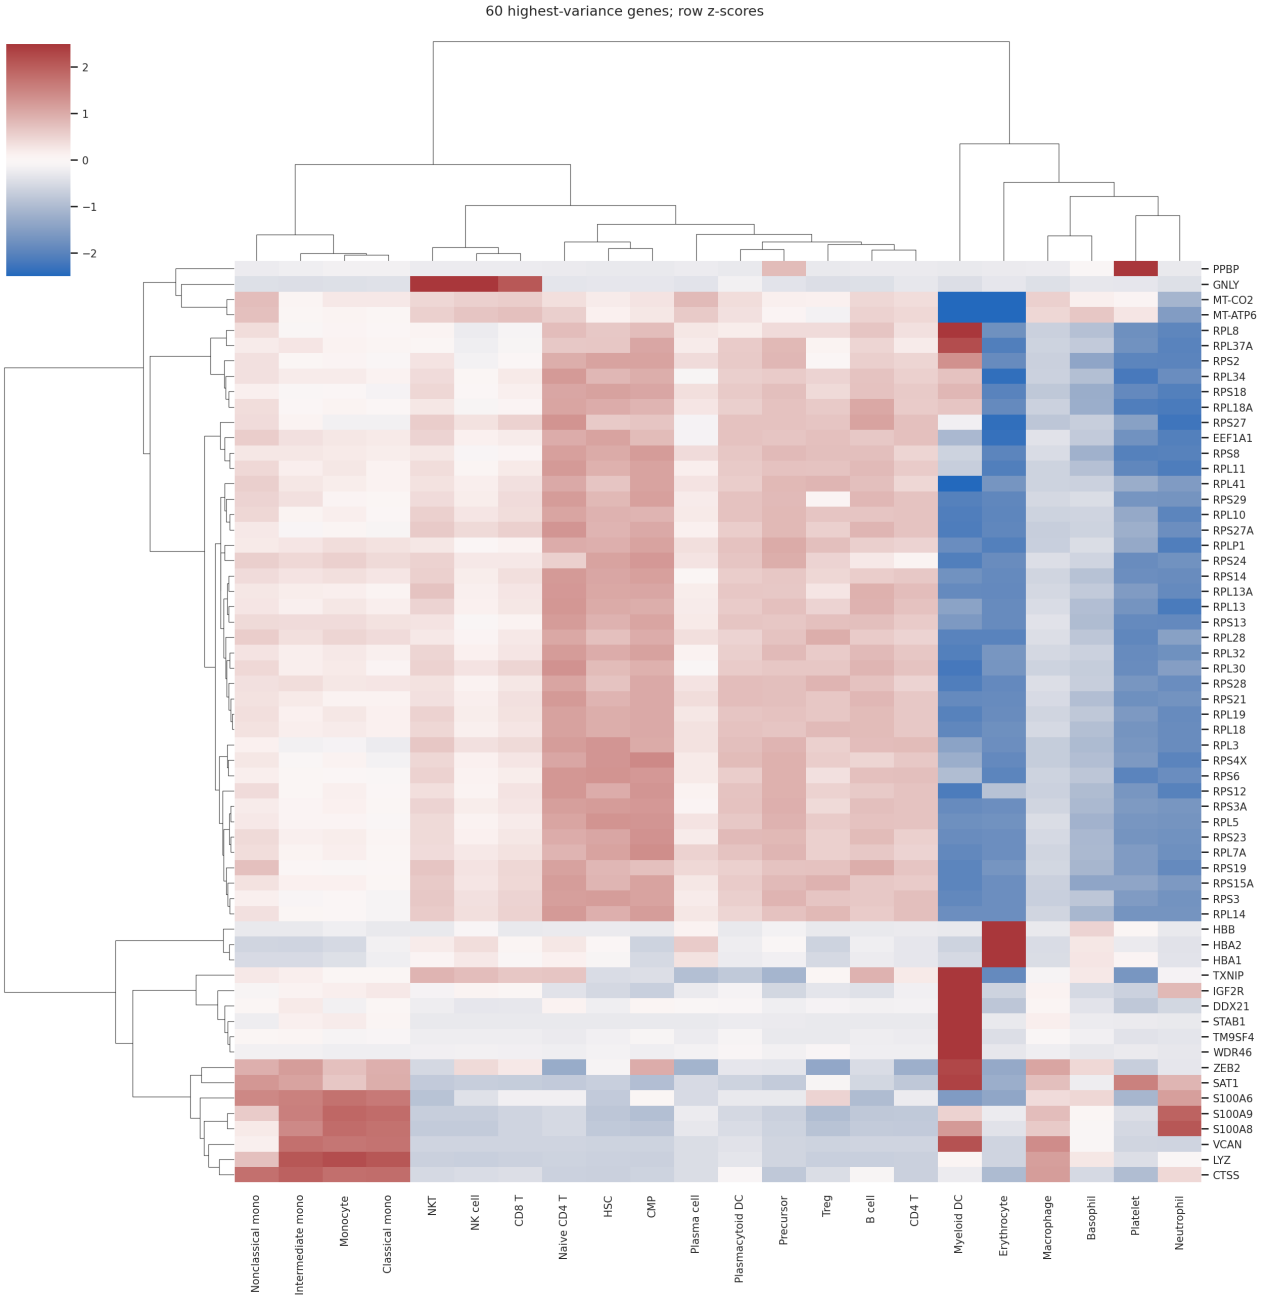
髓系树突细胞约 94.0% 的基因表达为零，保留分析但标注为低信息目标。零值不作为缺失值填补。缺少原始计数与细胞/供体重复，因此不重新进行计数归一化，也不做不适用的差异表达显著性检验。

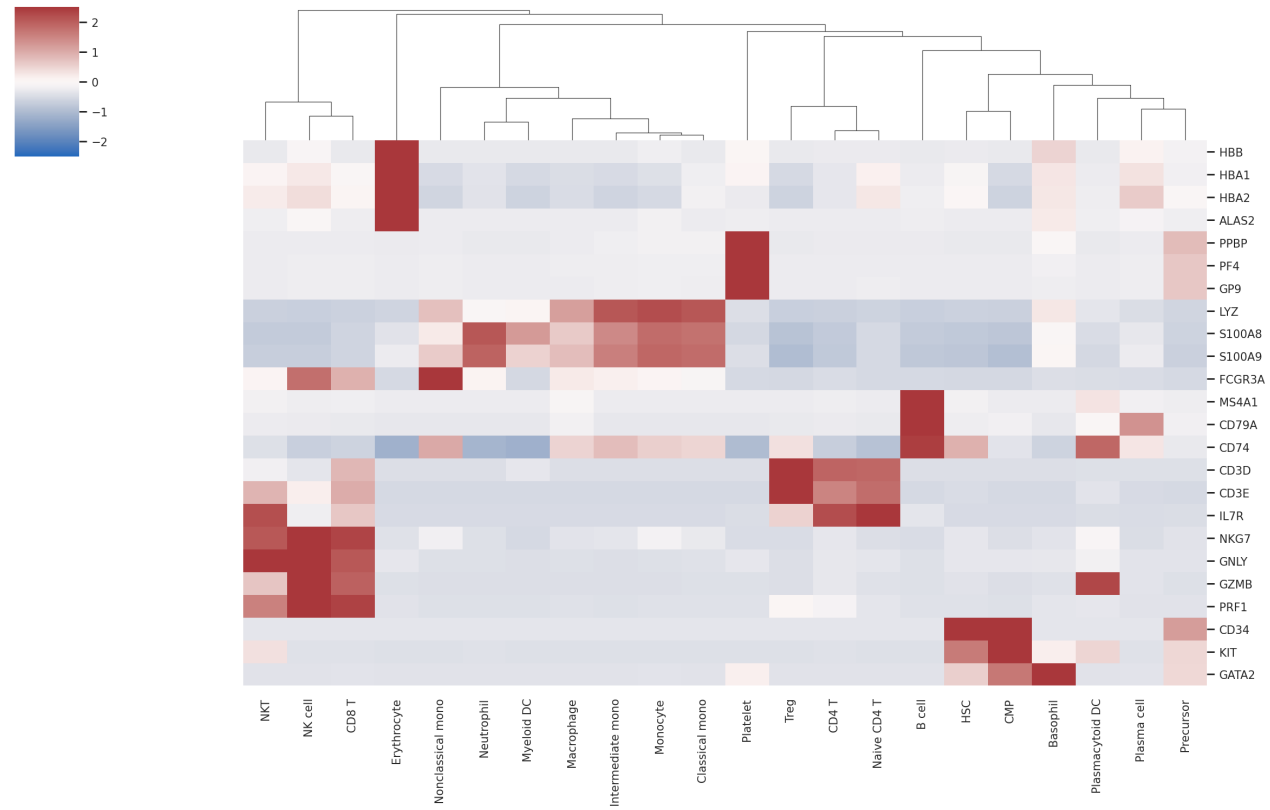


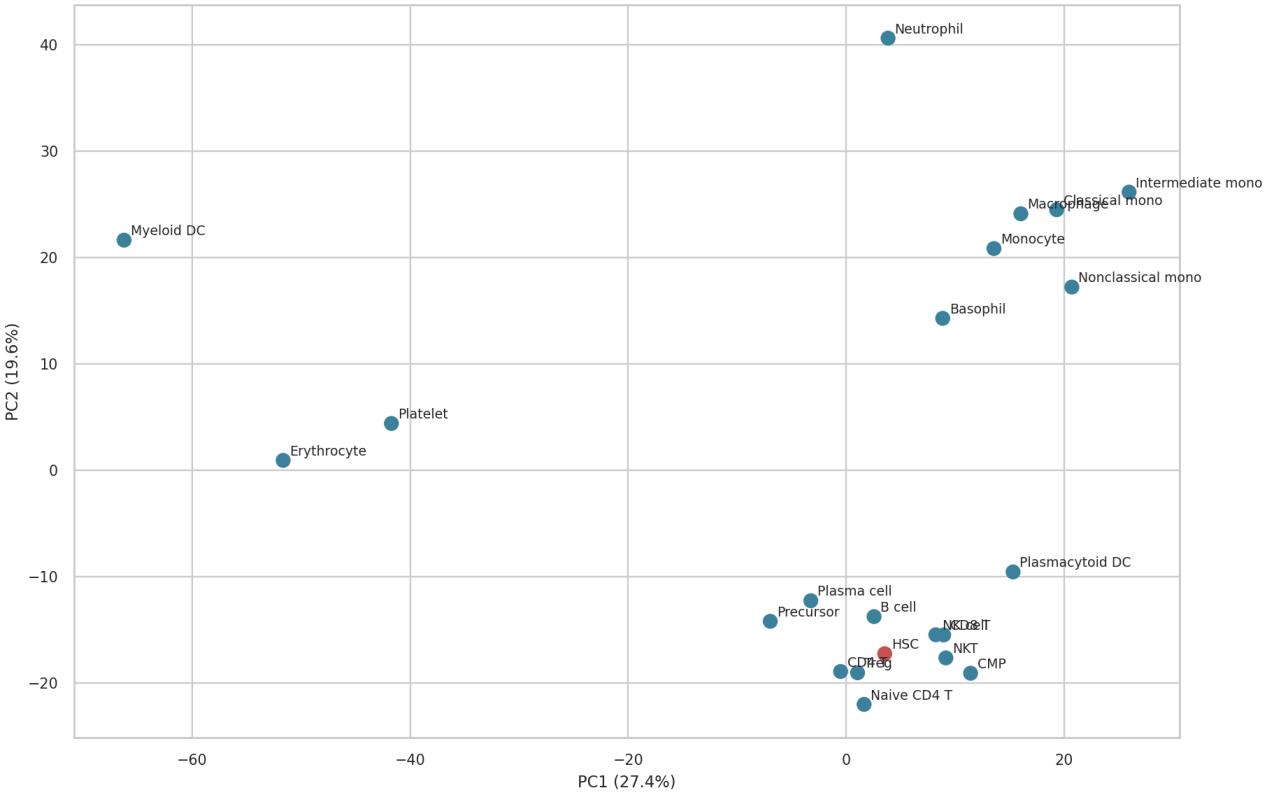


二、血液细胞探索性分析

高变基因热图选取方差最大的 60 个基因，逐基因跨细胞 z 标准化，Ward/欧氏距离双向聚类。高变基因中核糖体基因较多，反映整体表达差异，不能仅据此解释谱系；另补充预先指定的血液谱系标记热图。PCA 和细胞聚类使用 2,000 个高变基因，5 类仅用于探索，不声称是最优分类数。


60 highest-variance genes; row z-scores
2
1
0
−1
−2
PPBP
GNLY
MT-CO2
MT-ATP6
RPL8
RPL37A
RPS2
RPL34
RPS18
RPL18A
RPS27
EEF1A1
RPS8
RPL11
RPL41
RPS29
RPL10
RPS27A
RPLP1
RPS24
RPS14
RPL13A
RPL13
RPS13
RPL28
RPL32
RPL30
RPS28
RPS21
RPL19
RPL18
RPL3
RPS4X
RPS6
RPS12
RPS3A
RPL5
RPS23
RPL7A
RPS19
RPS15A
RPS3
RPL14
HBB
HBA2
HBA1
TXNIP
IGF2R
DDX21
STAB1
TM9SF4
WDR46
ZEB2
SAT1
S100A6
S100A9
S100A8
VCAN
LYZ
CTSS
Nonclassical mono
Intermediate mono
Monocyte
Classical mono
NKT
NK cell
CD8 T
Naive CD4 T
HSC
CMP
Plasma cell
Plasmacytoid DC
Precursor
Treg
B cell
CD4 T
Myeloid DC
Erythrocyte
Macrophage
Basophil
Platelet
Neutrophil





聚类 1：Erythrocyte；Platelet。

聚类 2：Myeloid DC。

聚类 3：Macrophage；Monocyte；Basophil；Neutrophil；Classical mono；Nonclassical mono；Intermediate mono。

聚类 4：NK cell；CD4 T；CD8 T；NKT；Treg；Naive CD4 T。

聚类 5：HSC；CMP；B cell；Plasmacytoid DC；Plasma cell；Precursor。

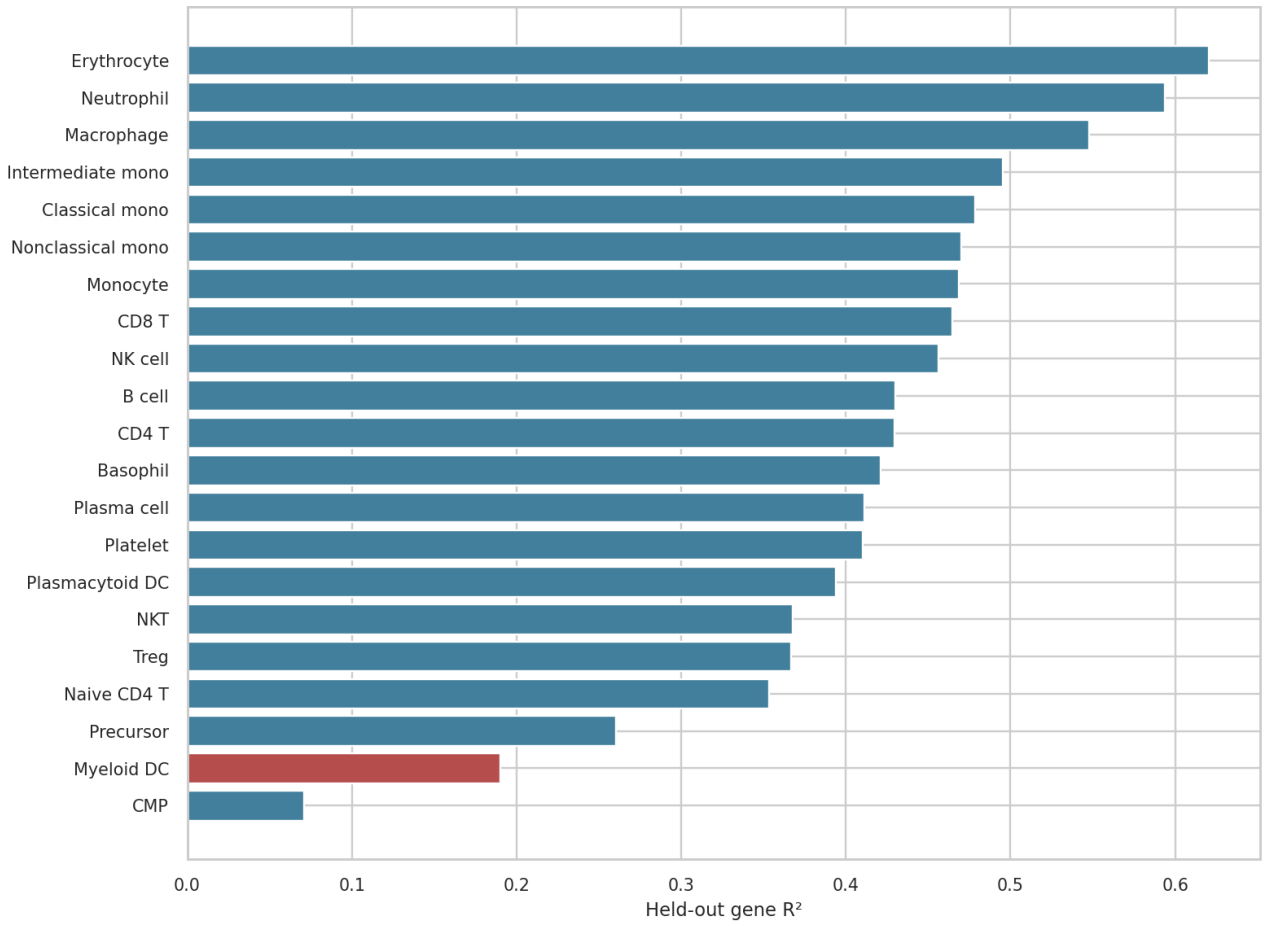
红细胞/血小板、T/NK、单核/髓系细胞呈现谱系相关的聚集；HSC、祖细胞及若干 B/树突细胞则在当前表示下聚到同一组，提示这不是纯粹的谱系树。髓系树突细胞单独成簇可能同时受高零比例影响。PCA 前两轴解释比例为 27.4% 和 19.6%。全部相关性见 eda/cell_spearman_correlations.csv。

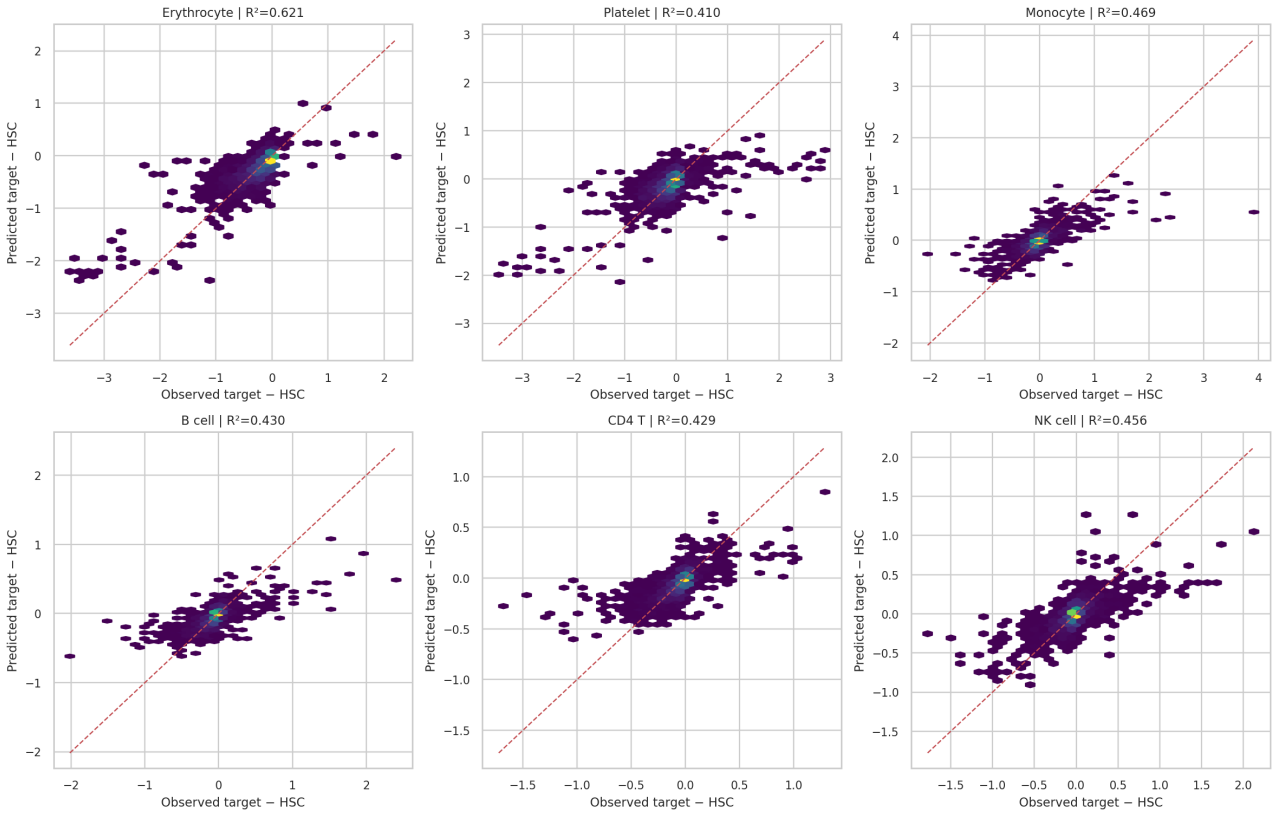
三、Lasso 建模与预测评价

对其余 21 种细胞分别构建 y = 目标细胞表达 - HSC 表达，X 为共同基因 × 全部 L1000 扰动。目标函数为 (1/2n)||y-截距-Xbeta||^2 + alpha||beta||1。模型使用训练集内拟合的扰动列标准化与响应标准化，系数表保留符号、标准化系数及原始单位系数。

共同基因固定随机划分为 9,552 个训练基因和 2,388 个测试基因。训练集内 3 折交叉验证搜索 24 个相对 alpha，采用 1 标准误规则偏向稀疏模型。测试集不调参，候选来自训练集模型，未用测试基因重新拟合。最终数值收敛检查通过，所有拟合最多使用 1175 次迭代。该矩阵 p<n，属于多特征稀疏回归，非严格的 p>n。

目标	测试R^2	测试RMSE	测试Pearson	非零扰动数	非零TF数
CMP	0.071	0.161	0.277	98	12
Erythrocyte	0.621	0.233	0.788	572	55
Platelet	0.410	0.327	0.641	581	67
Macrophage	0.548	0.194	0.741	762	84
B cell	0.430	0.160	0.657	707	80
Monocyte	0.469	0.195	0.686	683	85
NK cell	0.456	0.170	0.677	760	87
CD4 T	0.429	0.134	0.656	763	80
CD8 T	0.465	0.159	0.682	747	82
Basophil	0.421	0.242	0.650	416	56
Neutrophil	0.594	0.272	0.771	672	84
Myeloid DC	0.190	0.465	0.445	233	30
Plasmacytoid DC	0.394	0.148	0.629	787	79
Plasma cell	0.411	0.158	0.642	691	67
NKT	0.368	0.166	0.607	648	73
Treg	0.367	0.181	0.607	766	82
Classical mono	0.478	0.201	0.692	678	80
Nonclassical mono	0.470	0.192	0.686	858	97
Naive CD4 T	0.353	0.148	0.595	704	75
Intermediate mono	0.495	0.206	0.704	751	88
Precursor	0.261	0.088	0.511	393	49





全部模型优于训练均值基线，测试 R^2 范围 0.071 – 0.621；红细胞和中性粒细胞较高，共同髓系祖细胞较低。六个代表目标的单次训练响应打乱对照测试 R^2 均为负（-0.164 至 -0.091），仅说明打乱后失去匹配能力，不是正式显著性检验。

CV 路径中有 7 个目标的最小验证 MSE 位于最弱惩罚边界；已明确记录，后续可扩大搜索范围。主模型均按事先规定的 1SE 规则选取，未根据测试表现挑选 alpha。

四、候选扰动、TF 与跨细胞比较

全部扰动按 |标准化系数| 排序；只有匹配 Lambert 1,639 人类 TF 名单的候选进入 TF 表。RIOK2、DNMT3A、HDAC1、HMGB1、PML 等可作为其他调控扰动讨论，但不在本报告中误称为严格 TF。正系数表示联合拟合中的同向加权，负系数表示反向加权，不等价于已验证的过表达/敲除实验效果。

以下为六个代表目标各自按绝对系数排名前五的 TF，括号为带符号标准化系数：

红细胞：MYB (+0.073)，IRF3 (+0.059)，ELK3 (+0.058)，PREB (+0.057)，NFYB (-0.052)。

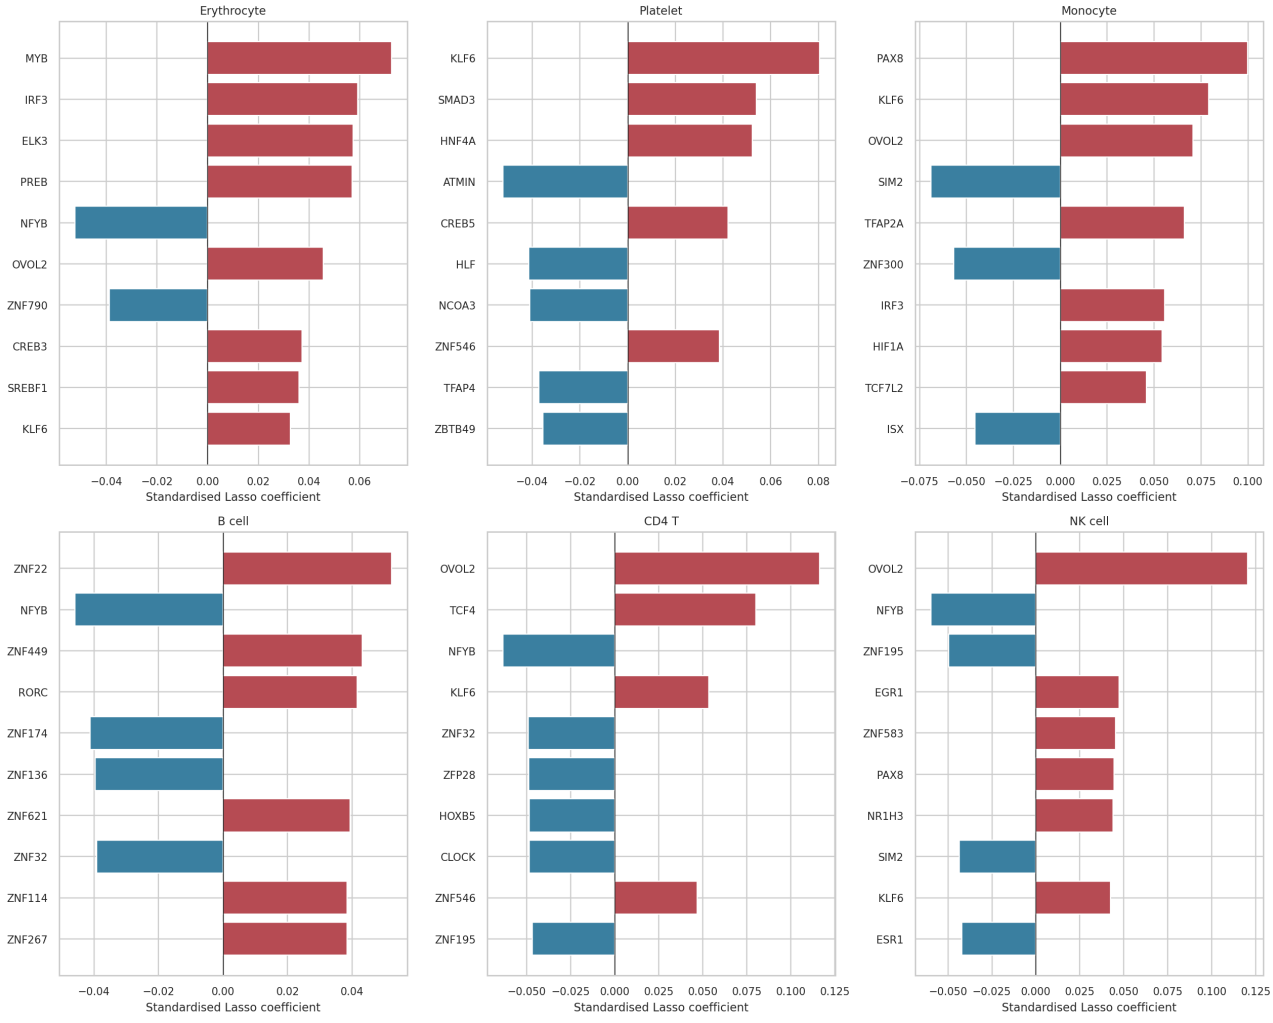
血小板：KLF6 (+0.081)，SMAD3 (+0.054)，HNF4A (+0.052)，ATMIN (-0.052)，CREB5 (+0.042)。

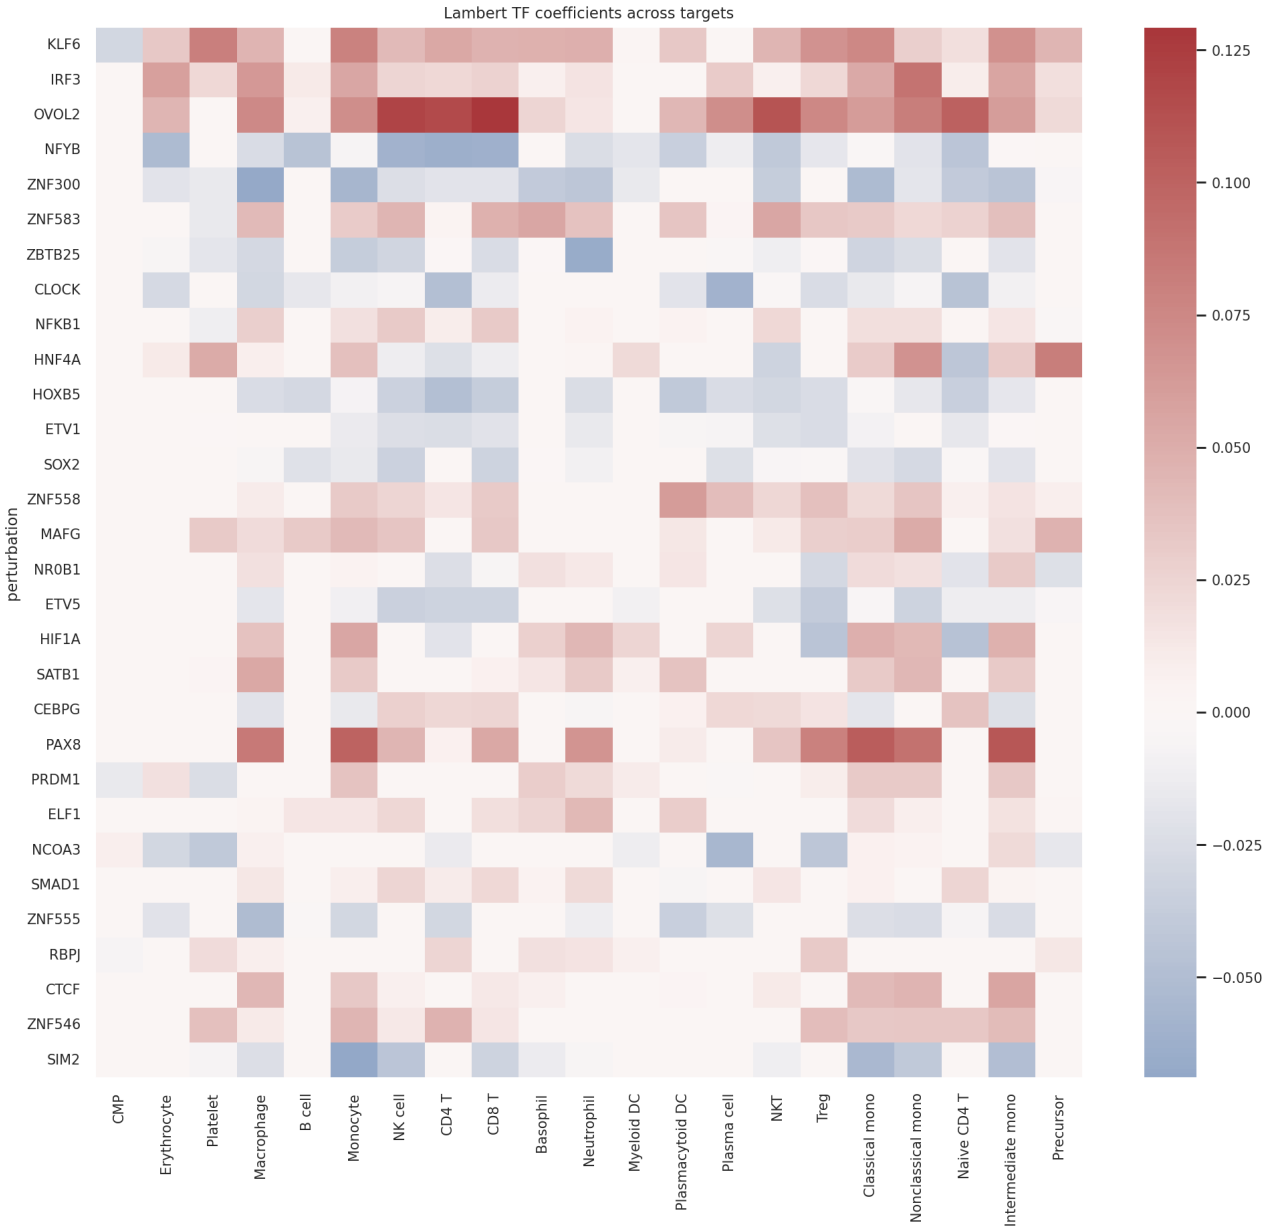
单核细胞：PAX8 (+0.100)，KLF6 (+0.079)，OVOL2 (+0.071)，SIM2 (-0.069)，TFAP2A (+0.066)。

B细胞：ZNF22 (+0.052)，NFYB (-0.046)，ZNF449 (+0.043)，RORC (+0.042)，ZNF174 (-0.041)。

CD4 T细胞：OVOL2 (+0.116)，TCF4 (+0.080)，NFYB (-0.063)，KLF6 (+0.053)，ZNF32 (-0.049)。

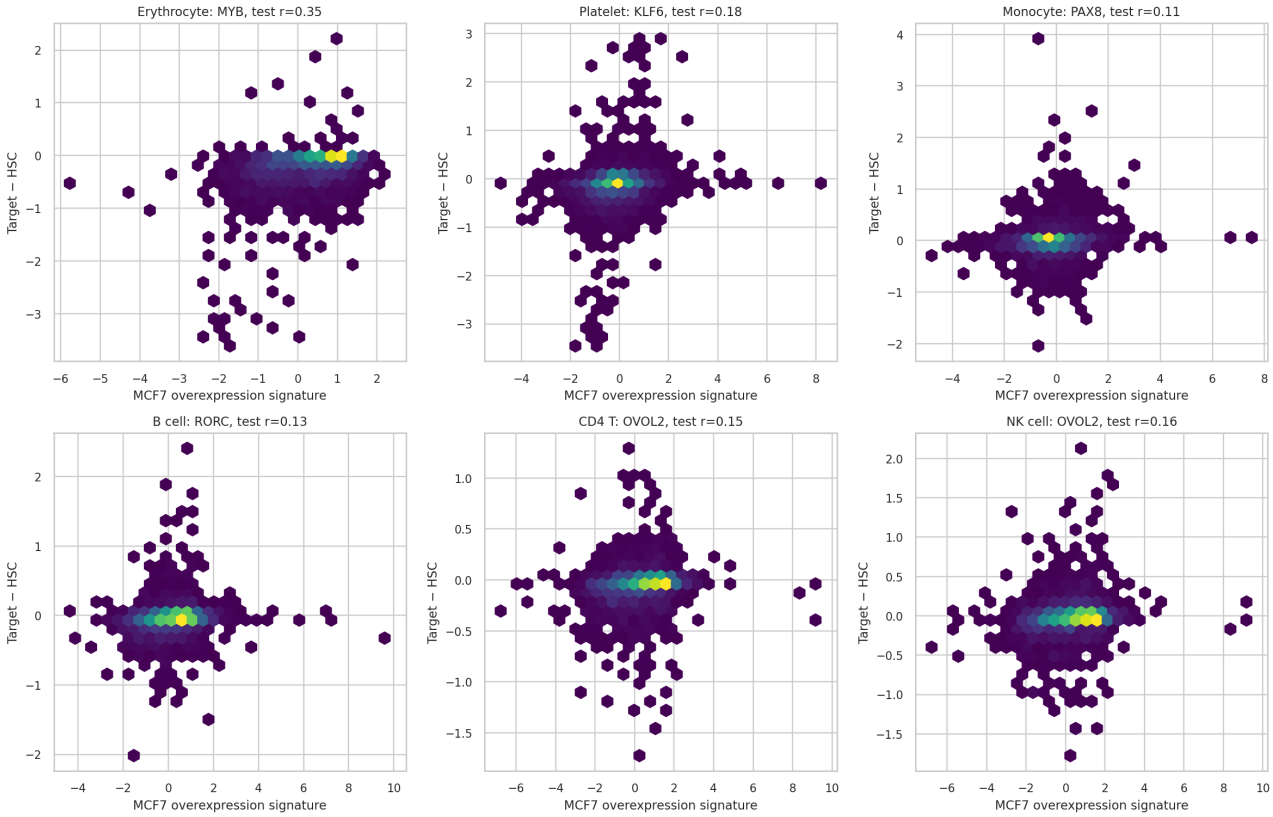
NK细胞：OVOL2 (+0.120)，NFYB (-0.060)，ZNF195 (-0.050)，EGR1 (+0.047)，ZNF583 (+0.045)。





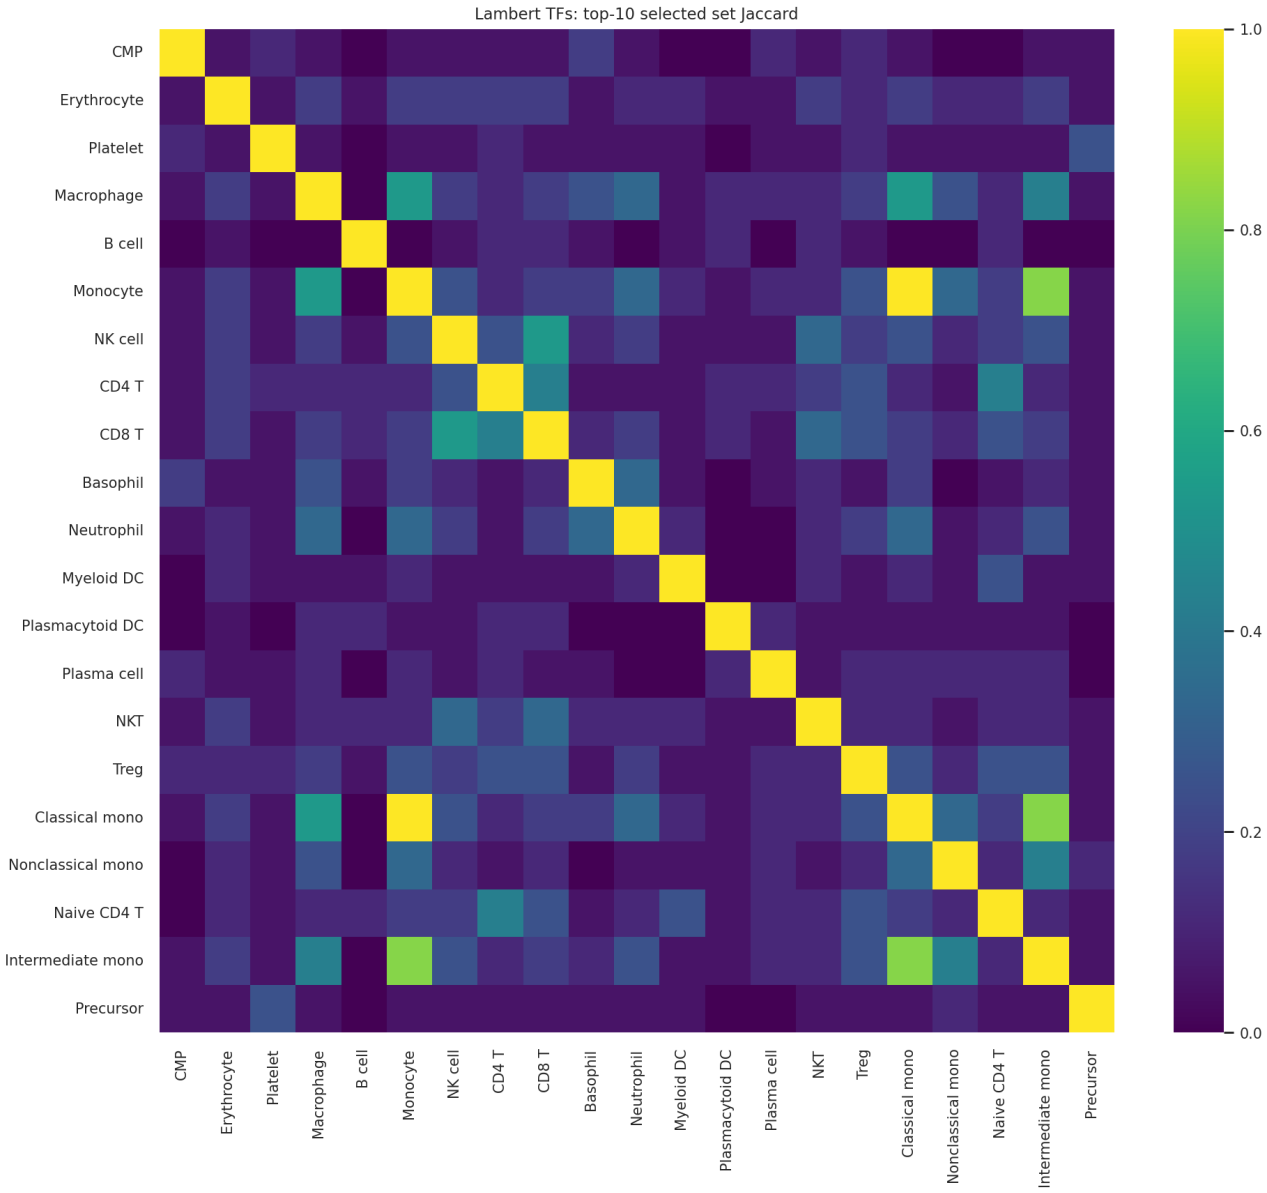
目标	代表TF	标准化系数	5次入选频率	训练边际相关	测试边际相关
红细胞	MYB	0.073	1.000	0.312	0.350
血小板	KLF6	0.081	1.000	0.183	0.177
单核细胞	PAX8	0.100	1.000	0.131	0.110
B细胞	RORC	0.042	1.000	0.138	0.135
CD4 T细胞	OVOL2	0.116	1.000	0.159	0.147
NK细胞	OVOL2	0.120	1.000	0.180	0.163

代表 TF 优先选择正系数、正训练边际相关且入选频率至少 60% 的最强候选；不使用测试相关选择候选。上表和图中，单个 TF 的测试相关通常明显低于联合模型的预测相关，说明这些候选只覆盖差异的一部分。五次入选不等于高置信因果证据，也不构成稳定性选择的错误率保证。



跨细胞比较使用每个目标前 10 个非零 TF 的 Jaccard：

cell_a	cell_b	n_shared	Jaccard	shared_TFs
Monocyte	Classical mono	10	1.000	HIF1A;IRF3;ISX;KLF6;OVOL2;PAX8;SIM2;TCF7L2;TFAP2A;ZNF300
Monocyte	Intermediate mono	9	0.818	HIF1A;IRF3;ISX;KLF6;OVOL2;PAX8;SIM2;TCF7L2;TFAP2A
Classical mono	Intermediate mono	9	0.818	HIF1A;IRF3;ISX;KLF6;OVOL2;PAX8;SIM2;TCF7L2;TFAP2A
NK cell	CD8 T	7	0.538	KLF6;NFYB;NR1H3;OVOL2;PAX8;ZNF195;ZNF583
Macrophage	Monocyte	7	0.538	IRF3;ISX;KLF6;OVOL2;PAX8;TFAP2A;ZNF300
Macrophage	Classical mono	7	0.538	IRF3;ISX;KLF6;OVOL2;PAX8;TFAP2A;ZNF300
Macrophage	Intermediate mono	6	0.429	IRF3;ISX;KLF6;OVOL2;PAX8;TFAP2A
Nonclassical mono	Intermediate mono	6	0.429	CTCF;IRF3;OVOL2;PAX8;TCF7L2;TFAP2A



谱系相近目标通常共享更多候选，尤其单核细胞及其亚型。也存在跨谱系共享，可能来自普遍转录程序或共同的 HSC 参照，不应直接解释为谱系特异因果调控。集合重叠不考虑符号，需结合带符号的系数矩阵查看同向或反向。

稳定性、预处理敏感性与解释边界

扰动库的覆盖范围也是关键限制：GATA2、MYB 有对应扰动列，但 GATA1、SPI1、CEBPA、RUNX1、TAL1、KLF1、PAX5、BCL11A、TCF7 在此文件中没有对应扰动列。它们作为响应基因出现不等于存在相应干预。模型无法选出未被提供的扰动，不能把这些经典造血 TF 未入选解释为其不重要。详细覆盖表见 qc/canonical_TF_coverage.csv。

五次训练基因 80% 子抽样已完成，全部候选的入选和同符号频率已保存。额外 log1p 后，入选扰动集合 Jaccard 范围为 0.511 – 0.774，前 20 扰动重叠为 8 – 16 个，说明预处理会改变部分候选，不能把单一排序视为唯一结果。此敏感性模型复用相对 alpha、未重新调参，R^2 对应不同响应尺度，不用于宣称取对数后的性能必然更优。

本分析是 MCF7 扰动特征与血液细胞平均表达差异的统计匹配，不证明 MCF7 中的扰动在血液背景中同样有效。PAX8、OVOL2 等候选即使排名较高，也需警惕组织背景或共线性的影响，不能直接称为血液分化主调控因子。优先核实候选 TF 在目标细胞的表达、相关文献及独立血液扰动证据，再考虑过表达、敲低及组合干预。

基因不是独立生物学重复；随机留出基因的 R^2 仅评价当前平均谱上的差异重建，不能外推为新供体预测准确率、分化成功率或实验因果效果。基因间共表达可能让随机划分偏乐观。建议用独立供体数据、按共表达模块/通路划分基因的验证，以及血液细胞背景的扰动实验检验候选。现有数据不能估计供体间变异或计算适当的差异表达 p 值。

文件与方法来源

完整质控见 qc/；探索数据见 eda/；全候选、TF 排名、测试指标、逐基因预测、稳定性和敏感性见 models/；图像为 figures/ 下的 PNG/PDF。README.md 记录全部参数，metadata.json 保存输入校验和与依赖版本。

TF 来源：Lambert SA et al. The Human Transcription Factors. Cell. 2018;172:650 – 665. doi:10.1016/j.cell.2018.01.029；PMID 29425488。名单 v1.01 的固定 GitHub 镜像及 SHA256 见 metadata.json。没有将示例 notebook 中训练集分数当作交叉验证分数。