以造血干细胞为参考的血液细胞表达差异与 L1000 扰动谱的 Lasso 匹配分析

第二次作业｜分析报告｜2026 年 10 月 26 日

摘要

本研究以造血干细胞（HSC）为共同参考，利用课程提供的血液细胞平均表达矩阵与 MCF7 过表达扰动特征，检验多个 L1000 扰动的线性组合能否重建不同血液细胞相对 HSC 的表达差异，并筛选候选转录因子（TF）。去重及标识对齐后纳入 11,940 个基因与 2,717 个扰动，其中 286 个扰动匹配人类 TF 名单。对 21 个目标细胞分别拟合 Lasso，在训练集内调参，并在独立留出的 2,388 个基因上评价。测试 R^2 为 0.071 – 0.621，其中红细胞为 0.621、中性粒细胞为 0.594。红细胞模型的候选 MYB 与测试基因差异的边际相关为 0.350；其他代表候选的单因子相关较弱，不能替代联合模型。单核细胞与经典单核细胞的前 10 个 TF 集合相同，也观察到跨谱系候选差异。结果支持以扰动表达特征提出可验证的调控假说，但受细胞背景、扰动库覆盖、汇总数据和验证设计限制，不能直接推断因果分化或重编程效率。

研究问题与数据

造血分化伴随多种转录调控程序变化。本研究的问题是：①哪些 MCF7 过表达扰动特征可以共同拟合目标血液细胞相对 HSC 的表达差异？②不同谱系是否共享候选 TF？③这种拟合在未用于训练的基因上表现如何，候选对基因重抽样和预处理是否敏感？这里的“ 匹配 ”是表达模式的统计匹配，而不是已经证明的细胞转化机制。

血液数据来自课程提供的 blood mean expr.csv，行为基因标识、列为 22 种细胞类型，HSC 列为 hematopoietic stem cell。L1000 数据来自课程提供的 L1000 MCF7_OE gene expression.h5，HDF5 属性明确其行为 gene_symbol、列为 cmap_name。数据从 chaigang713/CODEX 仓库读取，输入校验和已记录。CMap/L1000 的一般原理见文献 [1]；本文件的具体数据级别、处理时间、剂量及血液矩阵的原始细胞/供体组成未被课程文件完整说明，本研究不将平台文献的信息自动当作该文件的元数据。

参考细胞固定为 HSC，其余 21 个细胞全部建模；重点展示红细胞、血小板、单核细胞、B 细胞、CD4 T 细胞和 NK 细胞，覆盖不同谱系。细胞类型是平均谱，不存在可用于估计生物学重复变异的供体级观测。

一、质控与预处理

数据	原行数	列数	唯一基因数	重复行数	缺失	无穷值	最小值	最大值
blood	20001	22	19994	7	0	0	0.000	8.778
L1000	12328	2717	12327	1	0	0	-10.000	10.000

血液数据删除 7 个重复行（涉及 MATR3、MKKS、HERC3、POLR2J3、NPIPA9、PINX1），L1000 删除 1 个重复行（MIA2）；均保留原文件第一次出现。两套数据均无缺失值和无穷值。血液基因包含 580 个 Ensembl 格式标识，L1000 为符号格式；这些 Ensembl 行未精确匹配到 L1000，本次未推断其符号映射。

该损失已记录，后续可在核实版本后映射。

按共同标识和相同顺序对齐后，共有 11,940 个基因、2,717 个扰动，其中 286 个扰动匹配 Lambert 人类 TF 名单。没有零方差扰动被剔除。血液表达范围 0 – 8.778474；其完整归一化来源未知，主分析采用提供尺度，不再盲目取对数。L1000 范围约 -10 – 10，作为有符号扰动特征使用，不取对数，也不将其声称为已核实的原始 log-fold change。

髓系树突细胞约 94.0% 的基因表达为零，保留分析但标注为低信息目标。零值不作为缺失值填补。缺少原始计数与细胞/供体重复，因此不重新进行计数归一化，也不做不适用的差异表达显著性检验。

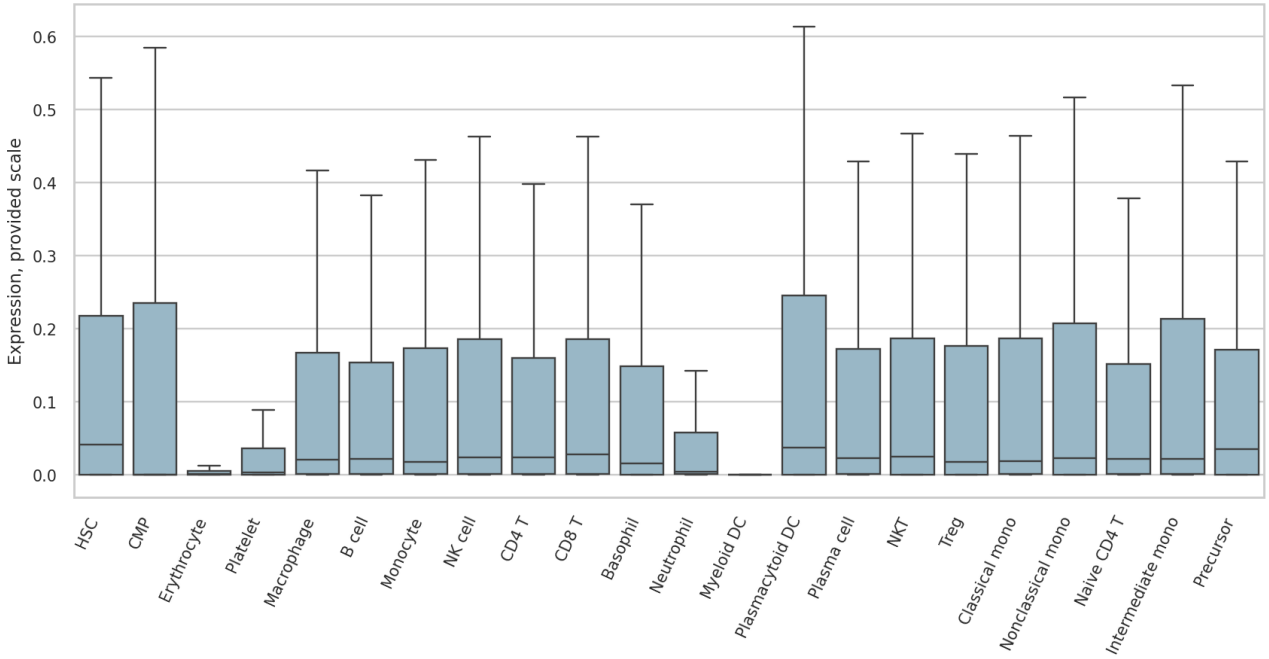


图1｜22种血液细胞的基因表达分布。箱线图隐藏离群点，使用文件提供的尺度。

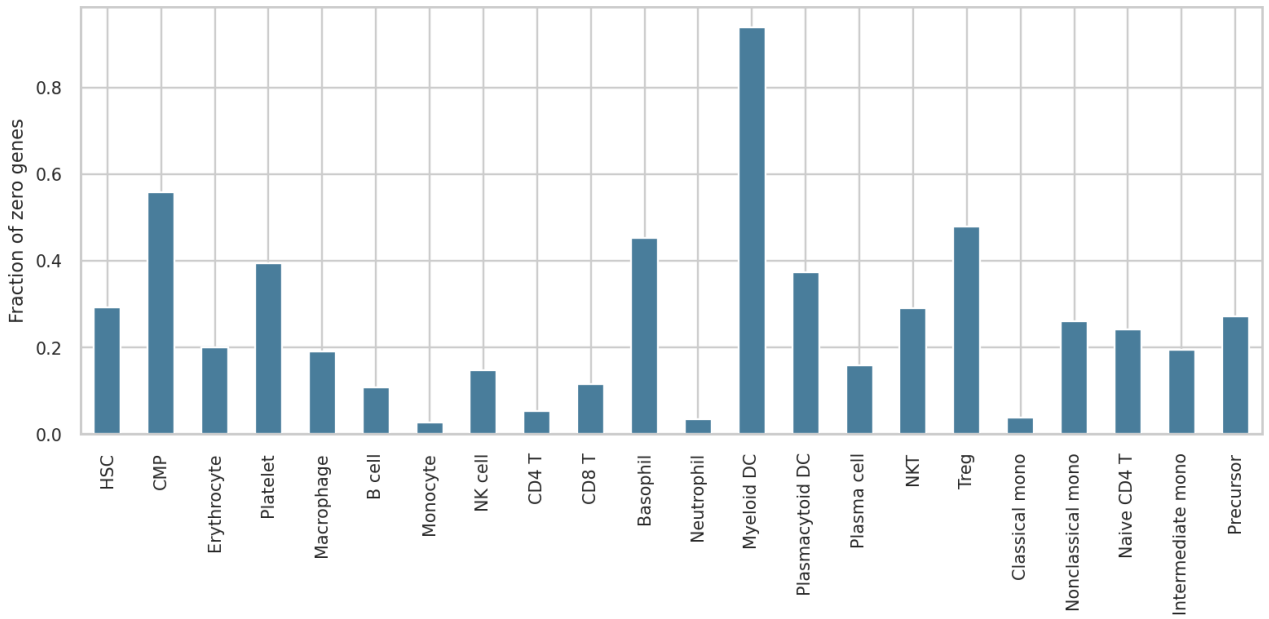


图2｜各细胞类型零表达基因比例。髓系树突细胞约94%的零值提示信息量不足。

二、血液细胞探索性分析

高变基因热图选取方差最大的 60 个基因，逐基因跨细胞 z 标准化，Ward/欧氏距离双向聚类。高变基因中核糖体基因较多，反映整体表达差异，不能仅据此解释谱系；另补充预先指定的血液谱系标记热图。PCA 和细胞聚类使用 2,000 个高变基因，5 类仅用于探索，不声称是最优分类数。

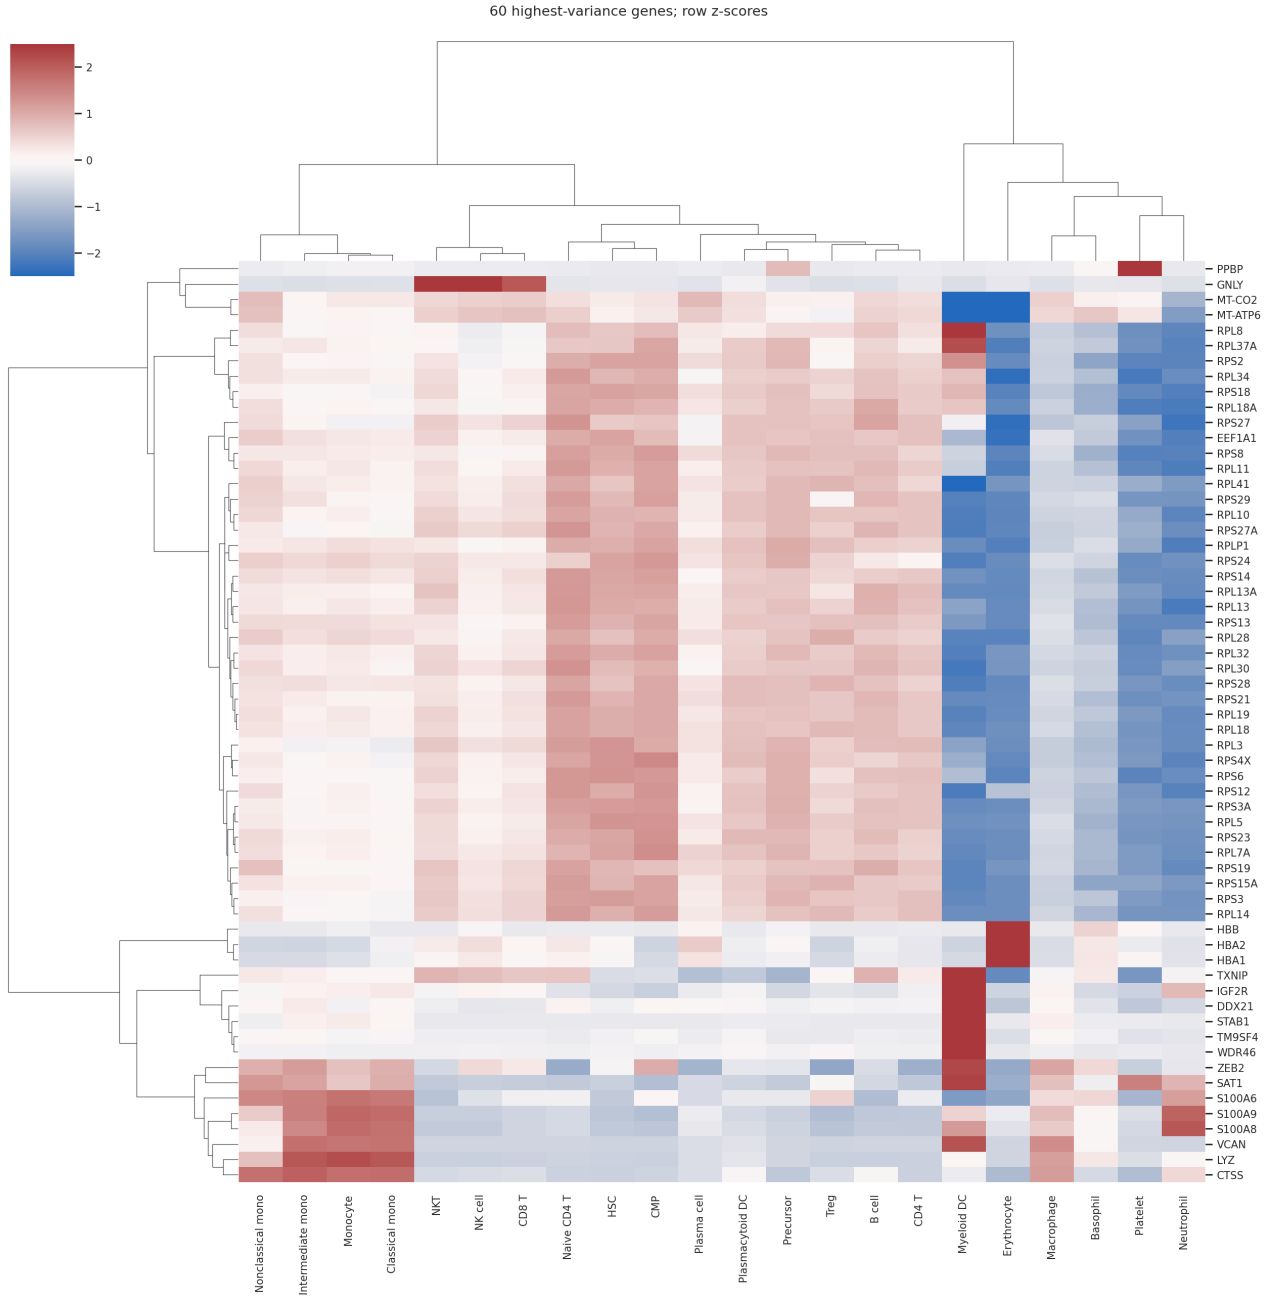


图3 | 60个高方差基因的聚类热图。颜色为逐基因跨细胞z分数，非原始表达量。

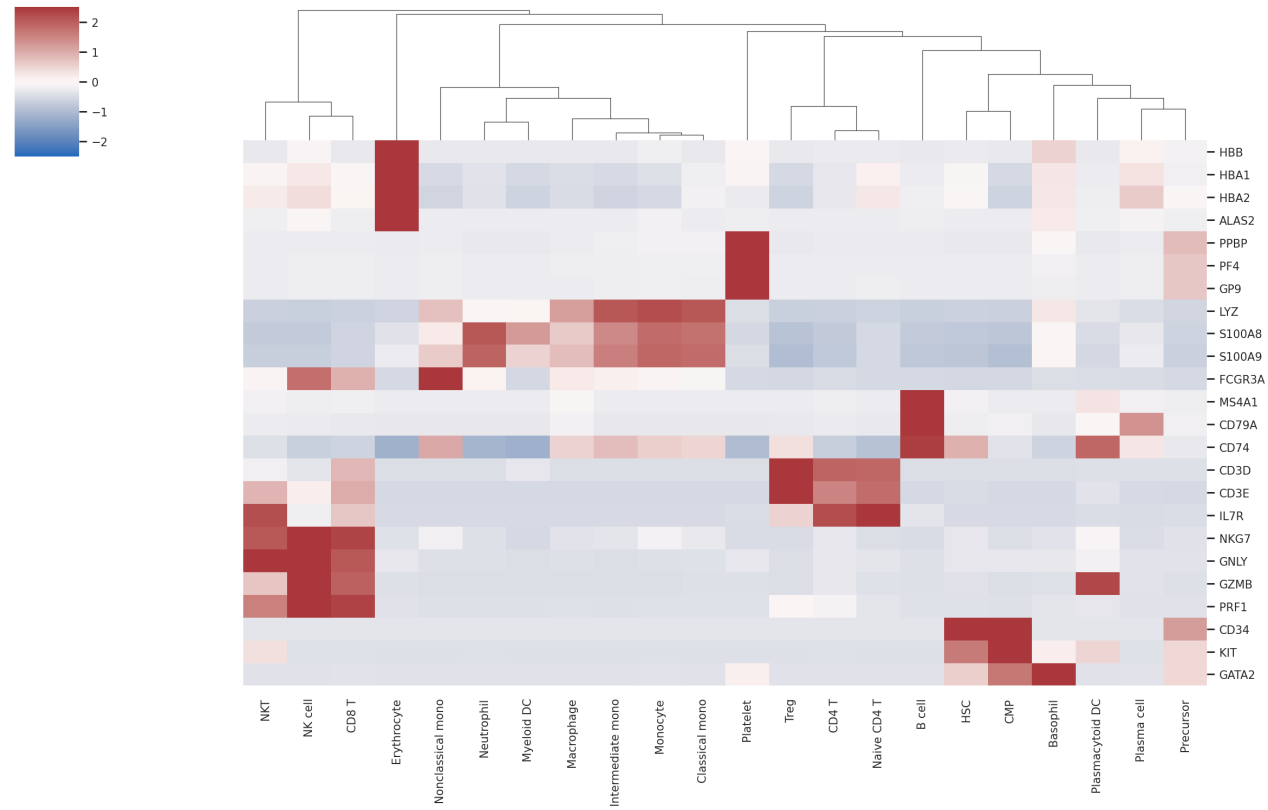


图4｜预设血液谱系标记的表达热图。行不聚类，列采用Ward聚类，颜色为逐基因z分数。

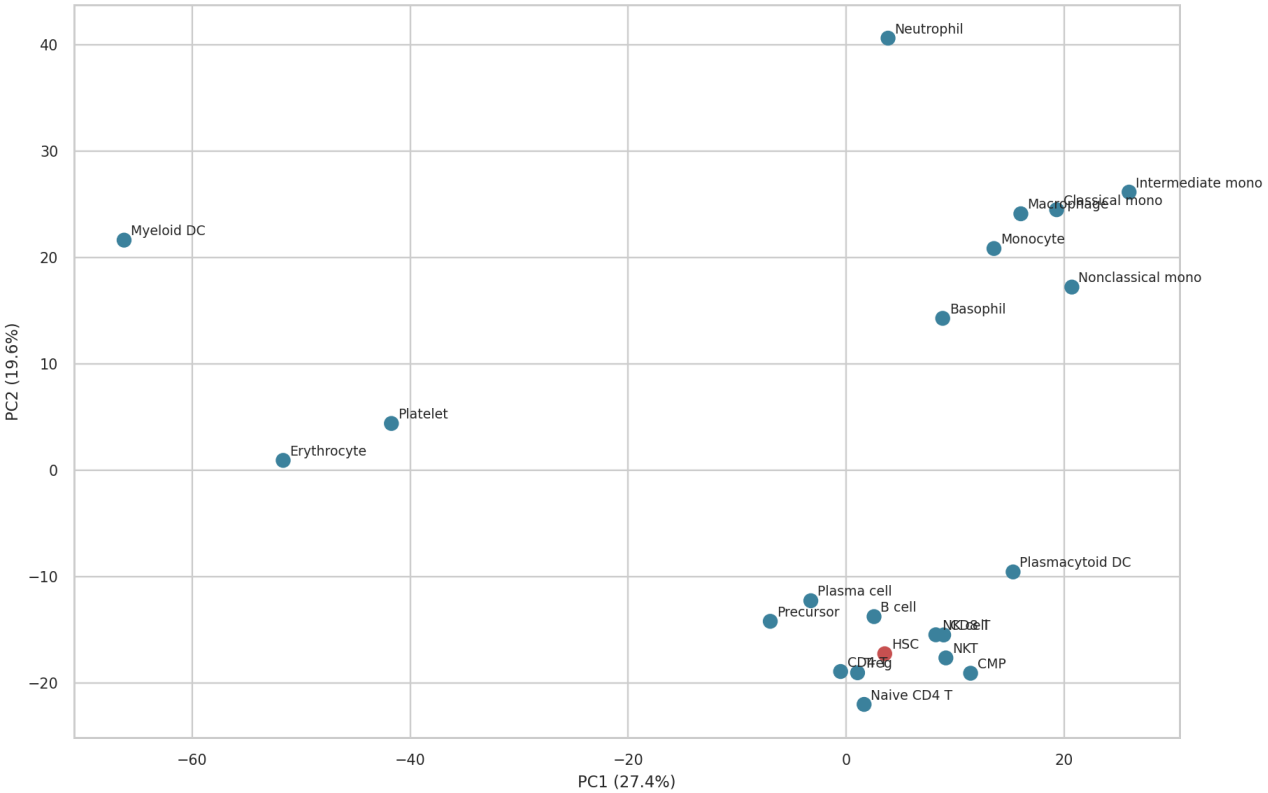


图5｜2,000个高变基因的细胞PCA。红点为HSC；PC1与PC2分别解释27.4%和19.6%的变异。

聚类 1：Erythrocyte；Platelet。

聚类 2：Myeloid DC。

聚类 3：Macrophage；Monocyte；Basophil；Neutrophil；Classical mono；Nonclassical mono；Intermediate mono。

聚类 4：NK cell；CD4 T；CD8 T；NKT；Treg；Naive CD4 T。

聚类 5：HSC；CMP；B cell；Plasmacytoid DC；Plasma cell；Precursor。

红细胞/血小板、T/NK、单核/髓系细胞呈现谱系相关的聚集；HSC、祖细胞及若干 B/树突细胞则在当前表示下聚到同一组，提示这不是纯粹的谱系树。髓系树突细胞单独成簇可能同时受高零比例影响。PCA 前两轴解释比例为 27.4% 和 19.6%。相关性分析另使用全部去重血液基因的 Spearman 相关，作为聚类解释的补充。

三、Lasso 建模与预测评价

对其余 21 种细胞分别构建 y = 目标细胞表达 - HSC 表达，X 为共同基因 × 全部 L1000 扰动。采用 Lasso [3]，目标函数为 (1/2n)||y-截距-Xbeta||^2 + alpha||beta||1。模型使用训练集内拟合的扰动列标准化与响应标准化，系数表保留符号、标准化系数及原始单位系数。

共同基因固定随机划分为 9,552 个训练基因和 2,388 个测试基因。训练集内 3 折交叉验证搜索 24 个相对 alpha，每个训练折独立计算 alpha_max = max|XTy|/n，24 个 alpha/alpha_max 在 1 至 0.01 间按对数间隔取值；采用最小平均验证 MSE 加其 1 标准误范围内惩罚最大的模型（1SE 规则），偏向稀疏解。测试集不调参，候选来自训练集模型，未用测试基因重新拟合。最终数值收敛检查通过，所有拟合最多使用 1175 次迭代。该矩阵 p<n，属于多特征稀疏回归，非严格的 p>n。

目标	测试R^2	测试RMSE	测试Pearson	非零扰动数	非零TF数
CMP	0.071	0.161	0.277	98	12
Erythrocyte	0.621	0.233	0.788	572	55
Platelet	0.410	0.327	0.641	581	67
Macrophage	0.548	0.194	0.741	762	84
B cell	0.430	0.160	0.657	707	80
Monocyte	0.469	0.195	0.686	683	85
NK cell	0.456	0.170	0.677	760	87
CD4 T	0.429	0.134	0.656	763	80
CD8 T	0.465	0.159	0.682	747	82
Basophil	0.421	0.242	0.650	416	56
Neutrophil	0.594	0.272	0.771	672	84
Myeloid DC	0.190	0.465	0.445	233	30
Plasmacytoid DC	0.394	0.148	0.629	787	79
Plasma cell	0.411	0.158	0.642	691	67
NKT	0.368	0.166	0.607	648	73
Treg	0.367	0.181	0.607	766	82
Classical mono	0.478	0.201	0.692	678	80
Nonclassical mono	0.470	0.192	0.686	858	97
Naive CD4 T	0.353	0.148	0.595	704	75

目标	测试R^2	测试RMSE	测试Pearson	非零扰动数	非零TF数
Intermediate mono	0.495	0.206	0.704	751	88
Precursor	0.261	0.088	0.511	393	49

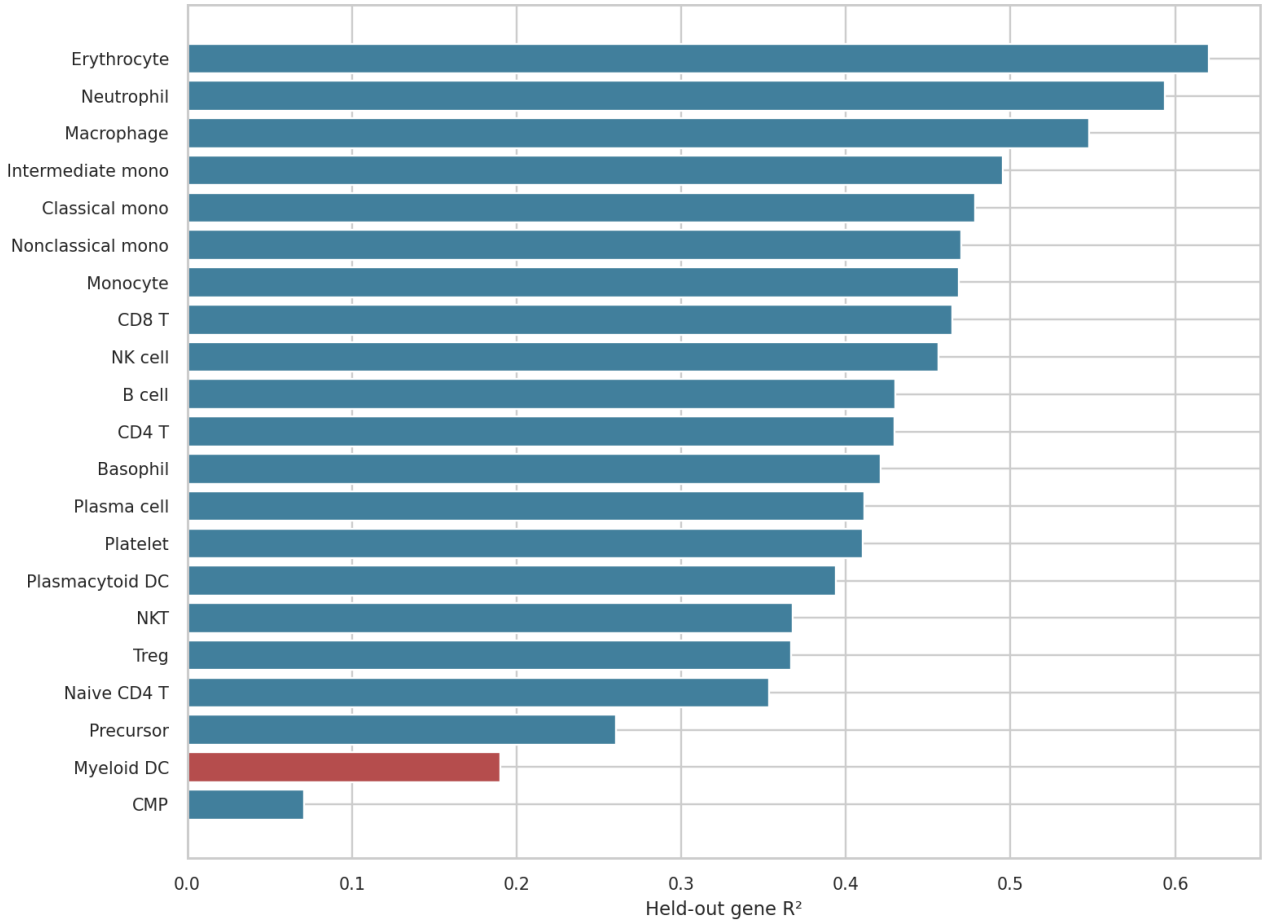


图6｜21个目标的测试基因R^2。红色标记高零比例的髓系树突细胞。

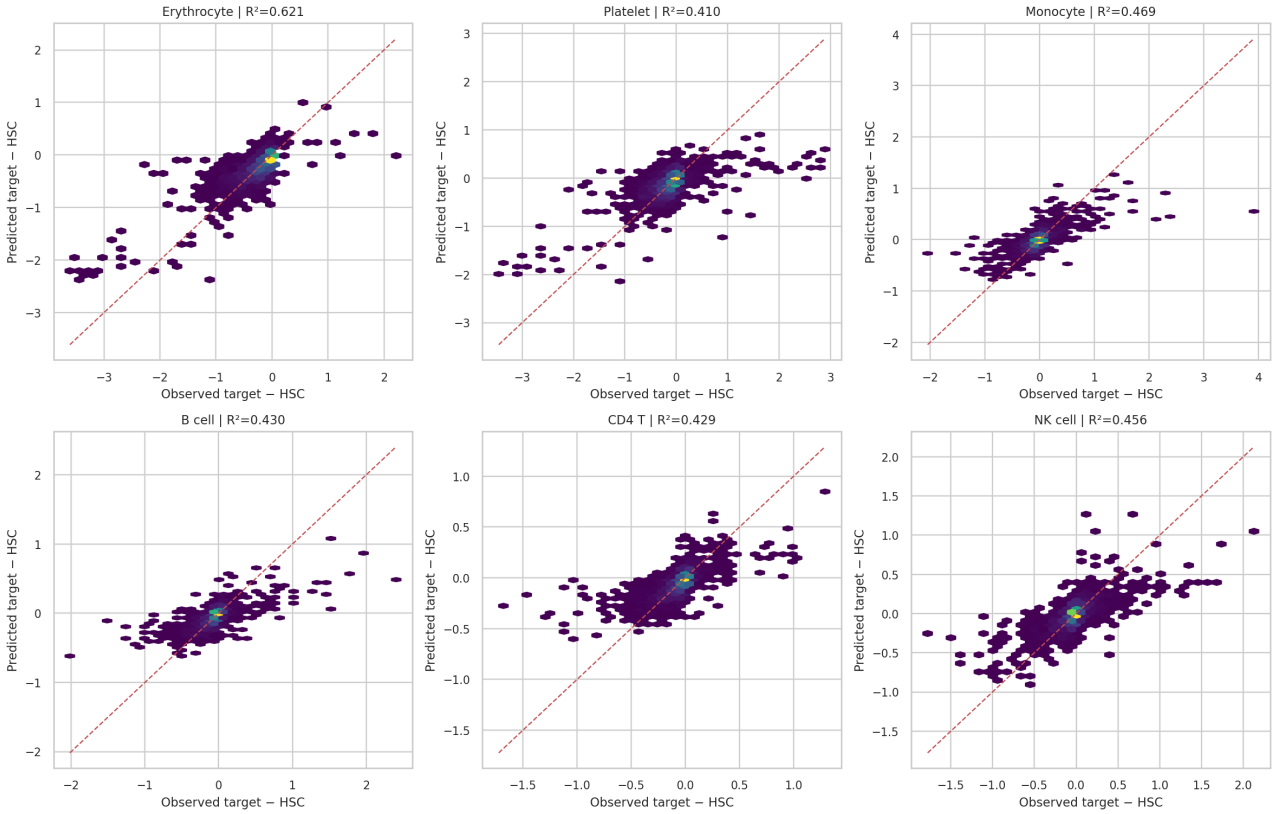


图7｜六个代表目标的联合模型预测。横轴为观察差异，纵轴为预测差异；红虚线为一致线。

全部模型优于训练均值基线，测试 R^2 范围 0.071 – 0.621；红细胞和中性粒细胞较高，共同髓系祖细胞较低。六个代表目标的单次训练响应打乱对照测试 R^2 均为负（-0.164 至 -0.091），仅说明打乱后失去匹配能力，不是正式显著性检验。

CV 路径中有 7 个目标的最小验证 MSE 位于最弱惩罚边界；已明确记录，后续可扩大搜索范围。主模型均按事先规定的 1SE 规则选取，未根据测试表现挑选 alpha。

四、候选扰动、TF 与跨细胞比较

全部扰动按 |标准化系数| 排序；只有匹配 Lambert 等人整理的 1,639 人类 TF 名单 [2] 的候选进入 TF 表。RIOK2、DNMT3A、HDAC1、HMGB1、PML 等可作为其他调控扰动讨论，但不在本报告中误称为严格 TF。正系数表示联合拟合中的同向加权，负系数表示反向加权，不等价于已验证的过表达/敲除实验效果。

以下为六个代表目标各自按绝对系数排名前五的 TF，括号为带符号标准化系数：

红细胞：MYB (+0.073)，IRF3 (+0.059)，ELK3 (+0.058)，PREB (+0.057)，NFYB (-0.052)。

血小板：KLF6 (+0.081)，SMAD3 (+0.054)，HNF4A (+0.052)，ATMIN (-0.052)，CREB5 (+0.042)。

单核细胞：PAX8 (+0.100)，KLF6 (+0.079)，OVOL2 (+0.071)，SIM2 (-0.069)，TFAP2A (+0.066)。

B细胞：ZNF22 (+0.052)，NFYB (-0.046)，ZNF449 (+0.043)，RORC (+0.042)，ZNF174 (-0.041)。

CD4 T细胞：OVOL2 (+0.116)，TCF4 (+0.080)，NFYB (-0.063)，KLF6 (+0.053)，ZNF32 (-0.049)。

NK细胞：OVOL2 (+0.120)，NFYB (-0.060)，ZNF195 (-0.050)，EGR1 (+0.047)，ZNF583 (+0.045)。

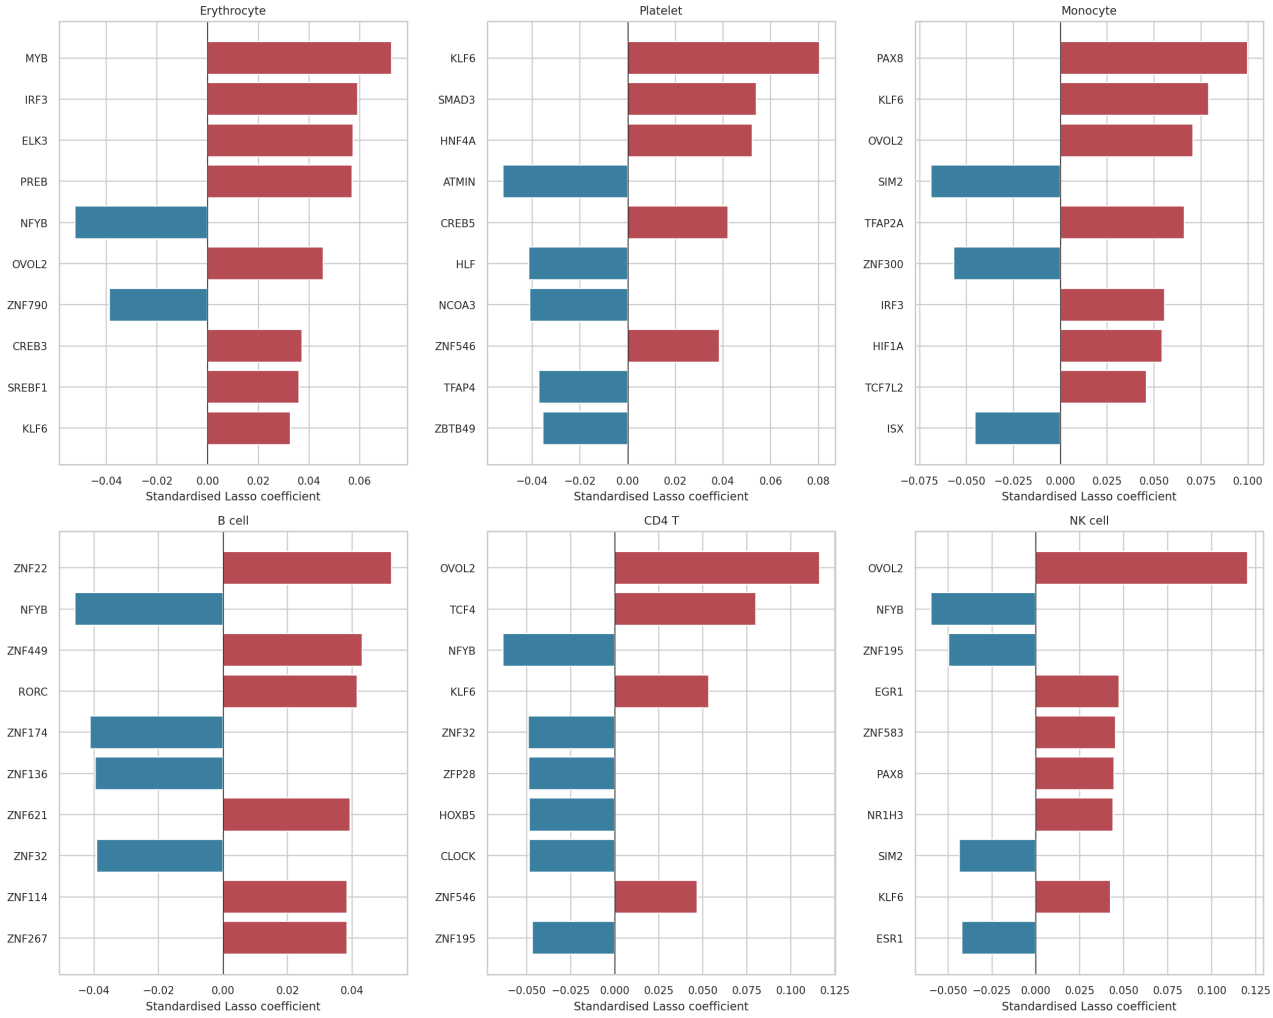


图8｜六个目标的前10个TF。按系数绝对值排序；红色为正权重，蓝色为负权重。

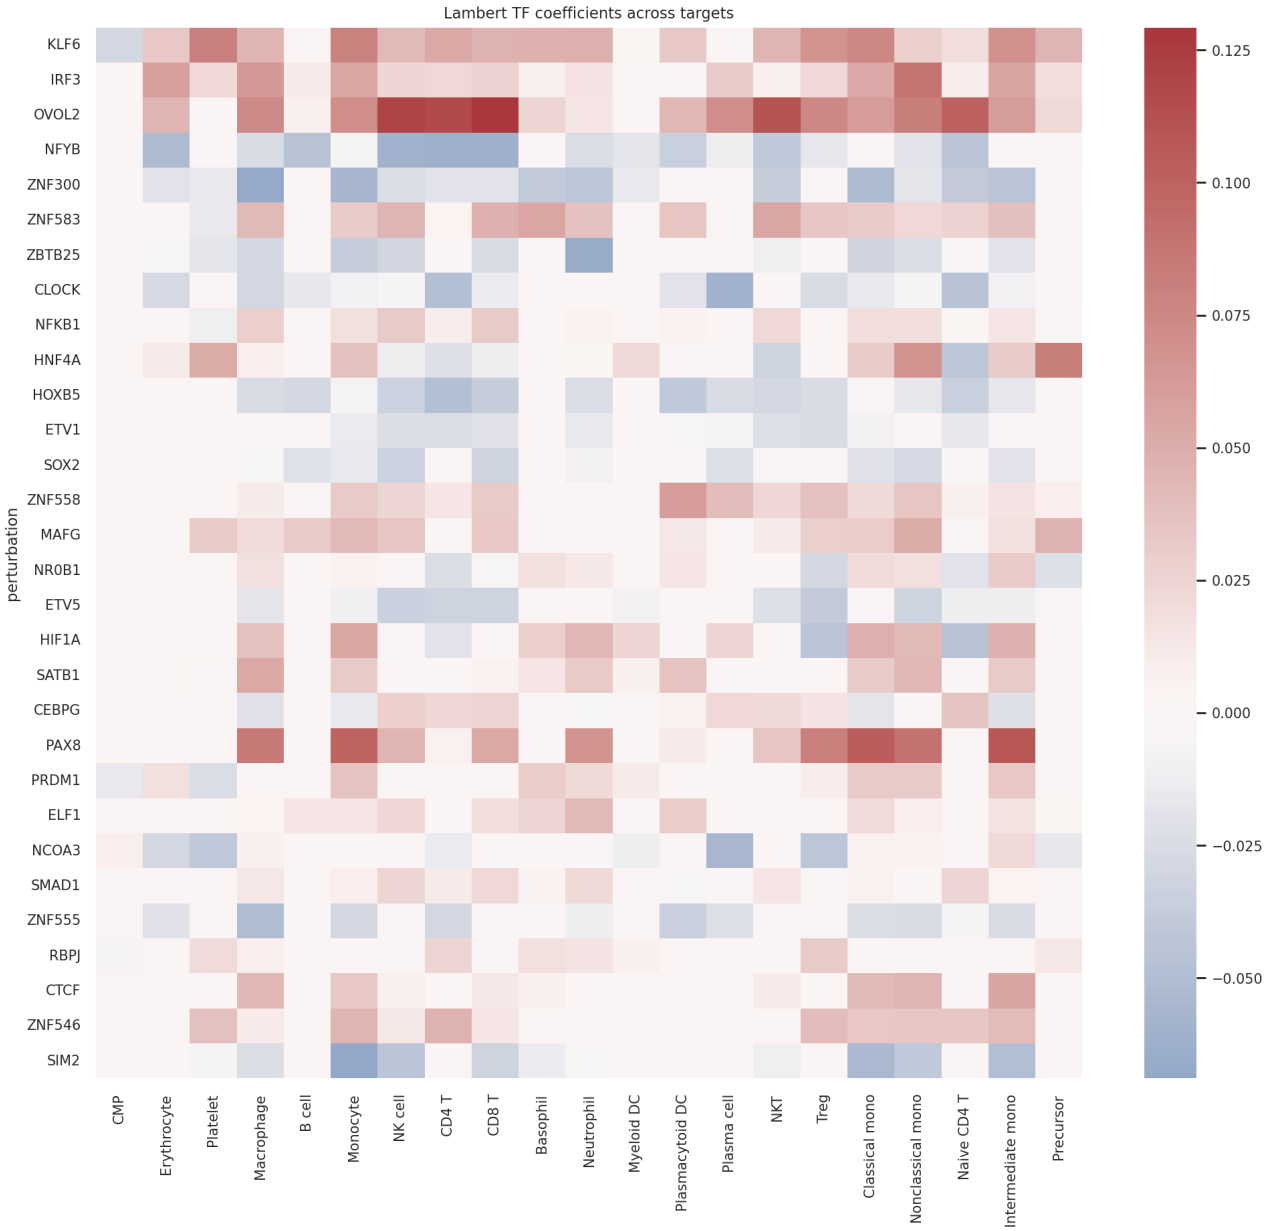


图9｜跨目标TF系数矩阵。展示在较多目标中入选的30个TF，颜色保留系数符号。

目标	代表TF	标准化系数	5次入选频率	训练边际相关	测试边际相关
红细胞	MYB	0.073	1.000	0.312	0.350
血小板	KLF6	0.081	1.000	0.183	0.177
单核细胞	PAX8	0.100	1.000	0.131	0.110
B细胞	RORC	0.042	1.000	0.138	0.135
CD4 T细胞	OVOL2	0.116	1.000	0.159	0.147
NK细胞	OVOL2	0.120	1.000	0.180	0.163

代表 TF 优先选择正系数、正训练边际相关且入选频率至少 60% 的最强候选；不使用测试相关选择候选。上表和图中，单个 TF 的测试相关通常明显低于联合模型的预测相关，说明这些候选只覆盖差异的一部分。五次入选不等于高置信因果证据，也不构成稳定性选择的错误率保证。

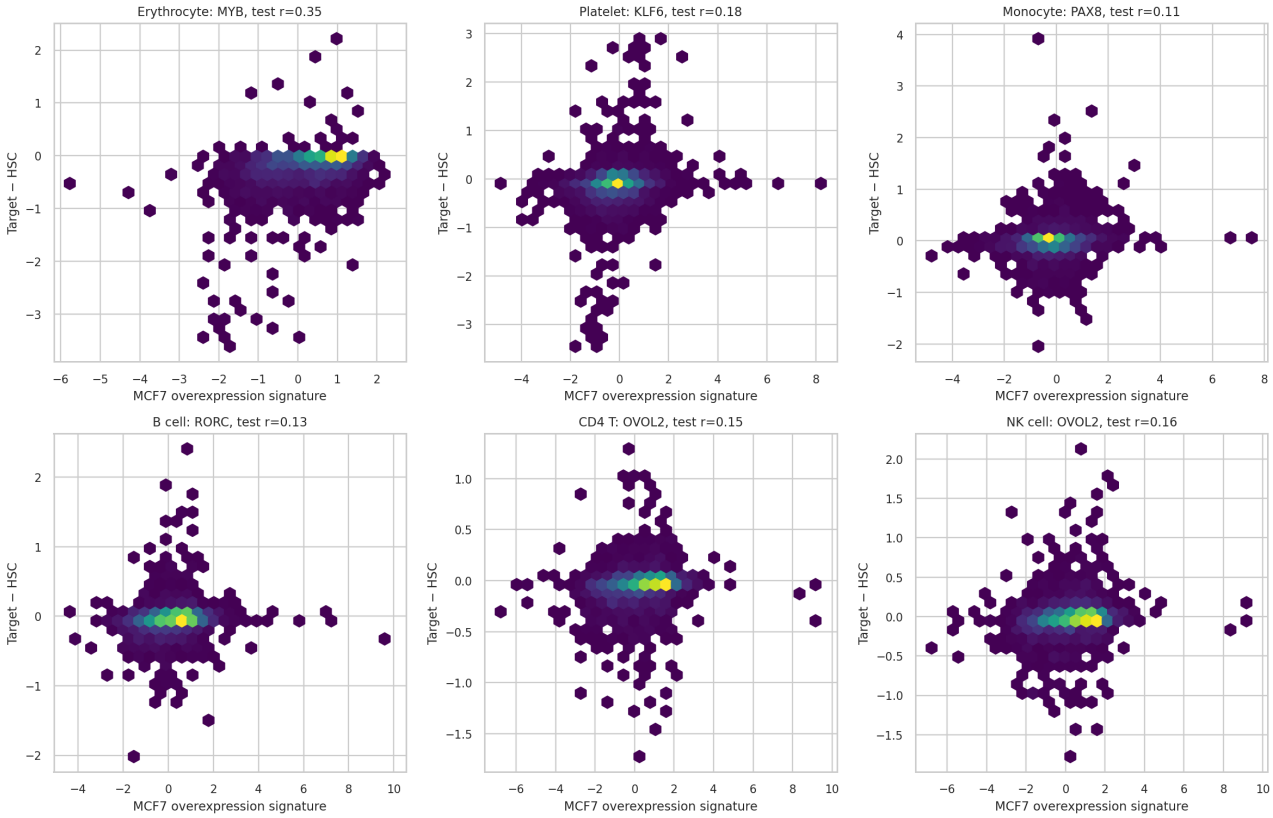


图10｜单个代表TF特征与目标差异的测试基因匹配。六边形颜色表示基因密度，r为边际相关。

跨细胞比较使用每个目标前 10 个非零 TF 的 Jaccard：

cell_a	cell_b	n_shared	Jaccard	shared_TFs
Monocyte	Classical mono	10	1.000	HIF1A;IRF3;ISX;KLF6;OVOL2;PAX8;SIM2;TCF7L2;TFAP2A;ZNF300
Monocyte	Intermediate mono	9	0.818	HIF1A;IRF3;ISX;KLF6;OVOL2;PAX8;SIM2;TCF7L2;TFAP2A
Classical mono	Intermediate mono	9	0.818	HIF1A;IRF3;ISX;KLF6;OVOL2;PAX8;SIM2;TCF7L2;TFAP2A
NK cell	CD8 T	7	0.538	KLF6;NFYB;NR1H3;OVOL2;PAX8;ZNF195;ZNF583
Macrophage	Monocyte	7	0.538	IRF3;ISX;KLF6;OVOL2;PAX8;TFAP2A;ZNF300
Macrophage	Classical mono	7	0.538	IRF3;ISX;KLF6;OVOL2;PAX8;TFAP2A;ZNF300
Macrophage	Intermediate mono	6	0.429	IRF3;ISX;KLF6;OVOL2;PAX8;TFAP2A
Nonclassical mono	Intermediate mono	6	0.429	CTCF;IRF3;OVOL2;PAX8;TCF7L2;TFAP2A

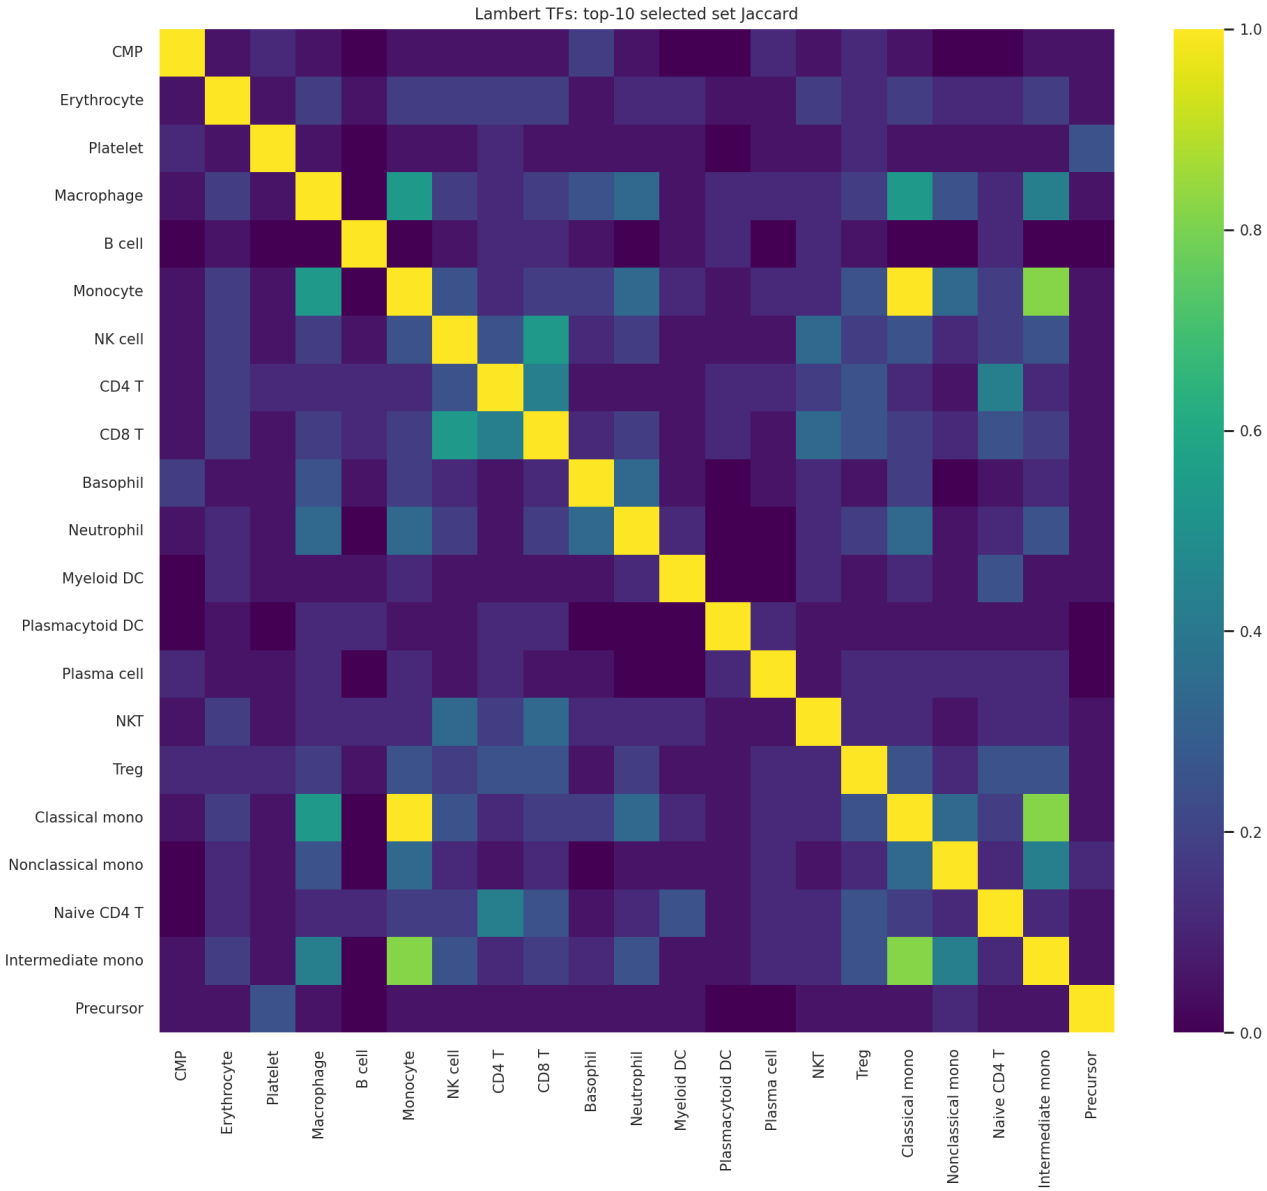


图11｜各目标前10个非零TF集合的Jaccard相似度。不包含系数方向，需与图9合看。

谱系相近目标通常共享更多候选，尤其单核细胞及其亚型。也存在跨谱系共享，可能来自普遍转录程序或共同的 HSC 参照，不应直接解释为谱系特异因果调控。集合重叠不考虑符号，需结合带符号的系数矩阵查看同向或反向。差异方面，红细胞与血小板仅共享前10 TF中的KLF6（Jaccard=0.053）；血小板与B细胞无重叠（Jaccard=0）；CD4 T与NK共享4个（Jaccard=0.250）。因此，部分共享程序与明显的目标间差异同时存在。

五、稳健性与局限性

扰动库的覆盖范围也是关键限制：GATA2、MYB 有对应扰动列，但 GATA1、SPI1、CEBPA、RUNX1、TAL1、KLF1、PAX5、BCL11A、TCF7 在此文件中没有对应扰动列。它们作为响应基因出现不等于存在相应干预。模型无法选出未被提供的扰动，不能把这些经典造血 TF 未入选解释为其不重要。这些缺失扰动的覆盖核对已保存。

五次训练基因 80% 子抽样已完成，全部候选的入选和同符号频率已保存。额外 log1p 后，入选扰动集合 Jaccard 范围为 0.511 – 0.774，前 20 扰动重叠为 8 – 16 个，说明预处理会改变部分候选，不能把单一排序

视为唯一结果。此敏感性模型复用相对 alpha、未重新调参，R^2 对应不同响应尺度，不用于宣称取对数后的性能必然更优。

本分析是 MCF7 扰动特征与血液细胞平均表达差异的统计匹配，不证明 MCF7 中的扰动在血液背景中同样有效。PAX8、OVOL2 等候选即使排名较高，也需警惕组织背景或共线性的影响，不能直接称为血液分化主调控因子。优先核实候选 TF 在目标细胞的表达、相关文献及独立血液扰动证据，再考虑过表达、敲低及组合干预。

基因不是独立生物学重复；随机留出基因的 R^2 仅评价当前平均谱上的差异重建，不能外推为新供体预测准确率、分化成功率或实验因果效果。基因间共表达可能让随机划分偏乐观。建议用独立供体数据、按共表达模块/通路划分基因的验证，以及血液细胞背景的扰动实验检验候选。现有数据不能估计供体间变异或计算适当的差异表达 p 值。

六、生物学解释：符合预期与待验证结果

6.1 谱系相关的聚集与 MYB 候选

T/NK 细胞、单核/髓系细胞在表达聚类中分别相近，单核细胞亚型也共享较多候选 TF，符合相近细胞状态包含共享表达程序的预期。然而红细胞和血小板聚集、HSC 与部分 B/树突细胞同组，不能简单视为真实发育树；平均表达、核糖体/代谢程序及低 RNA 特征都可能影响距离。预设标记热图中的 HBB/HBA、PPBP/PF4、LYZ/S100A8 等模式可作为细胞身份的辅助核查，不作为差异表达显著性证据。

MYB 在红细胞模型中系数为 +0.073，五次子抽样均入选，测试基因上的单扰动边际相关为 0.350，具有相对明确的同向匹配。小鼠 c-myb 缺失损害胎肝造血和成体型红细胞生成 [4]，因此 MYB 与红系/造血程序相关这一点有实验先验。但 MYB 的作用具有发育阶段和剂量依赖，且本研究的特征来自 MCF7；正系数不能推出“ 持续过表达 MYB 即可使 HSC 成熟为红细胞 ”。本结果支持优先验证表达程序重叠，而不直接指定干预方案。

6.2 KLF6：髓系先验与跨谱系匹配的区别

KLF6 在单核细胞中为正系数候选（+0.079），与其参与巨噬细胞炎症极化的实验研究具有方向上可讨论的联系。已有研究通过髓系细胞操作显示 KLF6 参与炎症相关基因调控 [5]。不过这些实验涉及巨噬细胞激活，不能直接外推为 HSC 向单核细胞分化的证据。血小板模型的 KLF6 系数更高（+0.081），其单扰动测试相关却仅为 0.177；现有文献 [5] 也不能证明它是巨核/血小板生成的驱动因子。该跨谱系匹配可能反映共有的应激或增殖相关表达成分，应进一步分解其贡献基因。

6.3 PAX8、OVOL2 与 RORC：需要优先排查背景效应

PAX8 在单核细胞中的标准化系数为 +0.100，但测试边际相关仅 0.110。PAX8 的经典表达与发育背景涉及甲状腺、肾脏等组织 [6]。这使其作为单核分化候选的解释具有不确定性：它可能在多变量模型中补偿相关扰动，而不是单核谱系特异调控。不能将同属 PAX 家族的 PAX8 与 B 细胞因子 PAX5 混淆；本文件没有 PAX5 扰动列。

OVOL2 在 CD4 T 与 NK 模型中均排名靠前，系数分别为 +0.116 与 +0.120，测试边际相关为 0.147 与 0.163。Ovol2 在乳腺上皮发育中限制上皮—间质转化的作用已有直接实验支持 [7]。这一背景与 MCF7 的乳腺来源密切相关，因此候选更可能首先提示源细胞背景的影响，而非已经发现新的 T/NK 分化开关。应检查匹配是否集中在上皮相关、细胞周期或广泛应激基因上。

RORC 在 B 细胞模型中作为正向代表候选，系数为 +0.042、测试边际相关为 0.135。RORC 编码的 RORgammat 与 Th17 程序有关 [8]，但基因级扰动标签不能确定具体异构体，更不能据此推断它是 B 细胞命运决定因子。该结果属于有待排查的跨谱系统计关联。

6.4 从候选匹配到后续验证

可首先在独立的血液单细胞/供体数据上重复构建细胞平均谱，检查 MYB、KLF6 等候选是否仍入选；对 PAX8、OVOL2 等候选优先核实血液细胞中的表达和染色质可及性。随后按共表达模块划分基因进行验证，并扩大 alpha 搜索、增加重抽样次数、比较 Elastic Net，以评估相关扰动替代和候选排序的不确定性。当前 7 个目标的最小 CV MSE 位于搜索下界，这些扩展是后续工作，尚未完成。

实验上应在与目标相符的造血前体细胞中设置空载体/阴性对照、候选单扰动及必要的组合扰动，独立重复，检测表达程序、相应谱系表面标记以及存活/增殖，区分分化效应与一般细胞状态改变。红细胞与血小板的成熟阶段缺乏细胞核，其平均 RNA 特征不能被简单理解为可在成熟细胞中重新启动的转录程序。以上为验证设计建议，本次没有实施这些实验。

七、结论

在当前数据和固定验证设计下，L1000 扰动特征的稀疏线性组合能够重建部分血液细胞相对 HSC 的表达差异，但目标间差异明显。MYB 与红系相关程序的匹配具有较清楚的先验支持；KLF6 可与髓系激活文献联系，而 PAX8、OVOL2、RORC 等跨背景候选需要更谨慎验证。相近目标之间共享候选的现象支持表达程序的关联性，但不能证明共同的因果分化机制。最终证据应来自独立血液数据与相符细胞背景下的实验，而非仅靠系数排名或测试基因的 R^2。

参考文献

[1] Subramanian A, et al. A Next Generation Connectivity Map: L1000 Platform and the First 1,000,000 Profiles. Cell. 2017;171:1437 – 1452.e17. DOI: 10.1016/j.cell.2017.10.049. https://pmc.ncbi.nlm.nih.gov/articles/PMC5990023/

[2] Lambert SA, et al. The Human Transcription Factors. Cell. 2018;172:650 – 665. DOI: 10.1016/j.cell.2018.01.029. https://pubmed.ncbi.nlm.nih.gov/29425488/

[3] Tibshirani R. Regression Shrinkage and Selection via the Lasso. Journal of the Royal Statistical Society, Series B. 1996;58:267 – 288. DOI: 10.1111/j.2517-6161.1996.tb02080.x.

[4] Mucenski ML, et al. A functional c-myb gene is required for normal murine fetal hepatic hematopoiesis. Cell. 1991;65:677 – 689. https://pubmed.ncbi.nlm.nih.gov/1709592/

[5] Date D, et al. Kruppel-like Transcription Factor 6 Regulates Inflammatory Macrophage Polarization. Journal of Biological Chemistry. 2014. https://pmc.ncbi.nlm.nih.gov/articles/PMC4036156/

[6] Poleev A, et al. PAX8, a human paired box gene: isolation and expression in developing thyroid, kidney and Wilms ’ tumors. Development. 1992. https://pubmed.ncbi.nlm.nih.gov/1337742/

[7] Watanabe K, et al. Mammary Morphogenesis and Regeneration Require the Inhibition of EMT at Terminal End Buds by Ovol2 Transcriptional Repressor. Developmental Cell. 2014;29:59 – 74. DOI: 10.1016/j.devcel.2014.03.006. https://pmc.ncbi.nlm.nih.gov/articles/PMC4062651/

[8] Ivanov II, et al. The orphan nuclear receptor RORgammat directs the differentiation program of proinflammatory IL-17+ T helper cells. Cell. 2006;126:1121 – 1133. DOI: 10.1016/j.cell.2006.07.035. https://pubmed.ncbi.nlm.nih.gov/16990136/

复现与智能体使用说明

分析由用户提供目标并使用 Codex 智能体执行数据读取、程序编写、计算和文献检索。数值结果来自实际运行，未将 AI 生成的机制假说写成实验事实。关键提示词、运行与排错记录单独保存在随附的 Homework2_工作记录.md；PDF 已内嵌主要图表，无需另附图表才能阅读。可复现代码、依赖、完整系数和质控表保存在 https://github.com/chaigang713/CODEX/tree/main/analysis 。