第二次作业：血液细胞与 L1000 转录组的 Lasso 回归分析

一、作业数据

通过以下链接，获取课程所需数据：

访问 https://share.weiyun.com/f2Z7iumY 获取 L1000 MCF7_OE gene expression.h5；

访问 https://share.weiyun.com/K3drqUE1 获取 08-高维回归.rar 中的 blood mean expr.csv、Tabula blood demo3.ipynb

二、作业内容

选择一种能够读取本地文件、编写和执行代码、分析运行结果的 **AI 智能体**（例如 Codex），使用血液细胞表达数据和 L1000 扰动表达谱，建立 Lasso 回归模型。以造血干细胞（HSC）为参考细胞类型，选择其他血液细胞类型作为目标，分析哪些 L1000 扰动的表达变化模式与目标细胞相对于 HSC 的表达差异相匹配。根据 Lasso 模型结果，分析候选转录因子及模型的预测表现。根据 Lasso 模型结果，分析候选转录因子及模型的预测表现。

三、任务细节及评分标准

1. 配置并使用 AI 科研智能体（30 分）：在本地环境中打开作业数据，向智能体描述分析目标，由智能体规划并执行分析步骤。保存至少一段具有代表性的任务指令（prompt）及智能体执行记录。说明智能体使用了哪些工具、生成了哪些文件，以及本人如何检查结果。

2. 数据分析（40 分）：检查缺失值、重复基因和基因标识符等（如有重复基因保留其中一个即可）。检查表达值的数值范围及可能需要的预处理，保存质控结果。利用 blood mean expr.csv 对不同血液细胞类型进行探索性分析（例如：根据数据特点选择适当的表达量变换和标准化方法、绘制基因表达热图、对细胞类型进行聚类等）。构建 Lasso 高维回归模型，使用血液细胞表达数据和 L1000 扰动表达谱，建立 Lasso 回归模型。根据回归系数或其他明确的统计指标，对候选扰动进行排序。选取若干代表性候选 TF，说明其与目标细胞类型表达差异的匹配情况。比较不同目标细胞类型的候选 TF 是否存在差异或重叠。

3. 生物学解释及拓展（30 分）：系统调研文献，对前述步骤发现的现象进行生物学解释。讨论如何设计后续分析或实验，检验候选 TF 的真实性和稳定性。结合自身的科研兴趣或在研课题，分析这批数据对自己的研究目标的潜在利用价值。还可以调研近期发表的高水平研究文章、综述乃至预印本，讨论自己研究兴趣所在领域在 AI 智能体时代的发展方向。

四、作业提交

1. 作业时间

10 月 26 日——11 月 7 日 24:00；

2. 提交内容

必要的提交文件（两项）：**a. 一份 pdf 格式的分析报告**，包含研究问题、数据与方法（使用数据、预处理步骤和统计模型等）、结果（展示主要图表、候选 TF 和模型评价指标等，不需要另附图表等）、生物学解释（如哪些结果符合预期，哪些结果值得进一步研究）、局限性（数据来源、细胞背景、模型假设和验证方法有哪些限制）；**b. 一份.md 格式的工作记录**，包含关键提示词、执行过程、重要修改及错误排查记录。

其他文件如主要分析代码或环境依赖和说明等，如有利于阐述分析结果也可一并提交，不计入评分标准。

3. 提交方式：将上述文件压缩为一个.zip 文件并以：学号—姓名—Homework2 命名。在截止日期（11 月 7 日 24:00）前通过 Email 发送至 2401110493@stu.pku.edu.cn，邮件主题为学号—姓名—Homework2